

분석적 사고력 훈련

5회차: 현업의 ML 모델링 방법

| 이준수 튜터

4회차 복습

- 성공적인 보고의 3단계 흐름
 - i. 결론: "우리는 **무엇을 해야 하는가?**"
 - ii. 핵심 근거: "**왜** 해야 하는가?"
 - iii. 분석 증명: "**어떻게** 알았는가?"
- TPO: 같은 발표라도 듣는 사람에 따라 다르게 말해야 합니다.
- Appendix: 발표에서 다루지 않은 모든 분석은 여기에

분석적 사고력 훈련

1. 분석의 '목적' 찾기 (문제 정의)
2. 가설을 세우고 테스트 가능한 형태로 변형하기
3. 문제의 원인을 찾는 방법 (Funnel / Cohort / Segmentation)
4. 결과 설명하는 방법 (스토리텔링)
5. 현업의 **ML 모델링 방법**
6. Case Study를 통한 분석적 사고력 훈련

실무의 냉혹한 현실

"데이터셋을 받았으니 `model.fit()` 만 하면 끝?"

현실은 그렇지 않습니다.

1. 실제 데이터는 깨끗하지 않습니다.

실제 데이터는 수많은 툴(Amplitude, GA, DB)에 흩어져 있고,
우리가 직접 분석 가능한 데이터셋을 만들어야 합니다.

2. Y값(정답지)은 존재하지 않습니다.

'LTV'나 'Fraud' 같은 Y값은 사전에 존재하지 않습니다.
우리가 직접 '정의'하고 '가공'해야 합니다.

3. 리소스는 유한합니다.

ML모델링 업무에 대한 우선순위를 비즈니스 가치로 증명해야 합니다.

3가지 Case Study를 통한 ML 실무 학습

- 💰 [Case 1] 고객 LifeTime Value (LTV) 예측
- 🔒 [Case 2] 사기 감지 (Fraud Detection)
- 👤 [Case 3] 개인화 (Personalization)

[Case 1] 고객 LifeTime Value (LTV) 예측

PM의 요청: "마케팅 비용을 효율화하고 싶습니다. 신규 유저의 LTV를 예측해서 '가치 있는' 유저에게만 광고비를 집중하고 싶어요."

LTV(고객 생애 가치)란? 고객 한 명이 우리 회사에 가져다줄 총 가치입니다.

💰 Tip 1: '장기 예측값'을 '단기 변수'로 예측

핵심 분석 과제:

- **Y (예측값):** LTV는 '1년 뒤'에나 알 수 있는 '장기적인' 지표입니다.
 - **X (단서):** 우리는 고객이 가입한 '첫날'의 '단기적인' 정보만 사용해야 합니다.
- ★ ML의 역할: 1년뒤를 기다리지 않고 고객의 **단기 피처(X)** (i.e. 첫날 방문 빈도)를 사용해, **장기 예측값(Y)** (i.e. 1년 뒤 수익)를 미리 예측합니다.

💰 Tip 2: 예측에 맞는 데이터셋 설계

1. Y값 (정답지) 만들기

- 먼저 현실적인 Y값을 정의합니다. (LTV = 고객 가입 후 1년 이내 총 수익)
- 학습 데이터를 만들기 위해 "1년 전 (2024년 11월)에 가입한 고객들"을 모두 불러오고, "2025년 10월까지의 총 구매액(LTV)"을 Y값으로 확정합니다.

2. X값 (단서) 만들기

이 고객들의 '**가입 첫날**' 데이터만 추출합니다.

- **유입 경로** : (i.e. SEO, Ads, Direct)
- **사용 기기 / OS** : (i.e. iPhone, Android, PC)
- **지역 / 언어** : (i.e. KR, UK / English, Spanish)

★ ML 프로젝트는 이렇게 '데이터셋 설계'에서 시작됩니다.

[Case 2] 사기 감지 (Fraud Detection)

학생: "사기(Fraud) 예측 모델을 만들었습니다. 제 노트북(Offline)에서 정확도가 99%가 나왔습니다! 완벽합니다!"

현업 분석가: "이 모델은 쓸 수 없습니다. **Offline**의 함정에 빠졌거나, **불균형** 데이터를 잘못 해석했을 가능성이 큼니다."

🔒 Tip 1: '정확도'의 함정 (불균형 데이터)

사기 거래는 보통 전체 거래의 ~0.1%에 불과합니다. (총 100,000건 중 100건이 사기)
모델이 "모두 정상"이라고만 예측한 경우의 **Confusion Matrix**를 봅시다:

	예측: 정상(0)	예측: 사기(1)
실제: 정상(0)	99,900 (True Negative)	0 (False Positive)
실제: 사기(1)	100 (False Negative)	0 (True Positive)

- **정확도 (Accuracy):** $99,900 / 100,000 = 99.9\%$ (숫자상 완벽해 보임)
- **재현율 (Recall):** $0 / 100 = 0\%$ (실제 사기 주문을 단 한 건도 못 잡음)

★ 불균형 데이터에서는 '정확도'만 쓰면 안됩니다.

비즈니스 목적(Recall)에 맞는 지표를 봐야 합니다.

Tip 2: Data Leakage 조심하기

1. '미래의 정답'을 훔쳐봄 (Target Leakage)

피쳐(X): `chargeback_received` (카드사 환불 접수 여부)

논리 오류: '환불'은 '사기 발생' 이후에 생기는 '미래의 결과'입니다.

2. '옆 사람의 시험지'를 훔쳐봄 (Train-Test Contamination)



전체 데이터(10만 건)로 평균값을 구해 결측치를 채움 -> Train / Test로 분리

논리 오류: **Train** 데이터가 '**Test** 데이터의 평균값(정답지)'를 미리 알아버렸습니다.



데이터를 먼저 Train / Test로 분리 -> 'Train Set'의 평균값만으로 'Train Set'과 'Test Set' 채움

★ Data Leakage는 모델의 신뢰도를 파괴합니다. 오직 '예측 시점'에 존재하는 정보만으로 피쳐(X)를 설계하고 모델을 학습시켜야 합니다.

Tip 3: '위험도'에 따른 차등 정책

PM의 질문: "모델이 완벽하지 않다면, 어떻게 믿고 적용하죠? 정상 고객을 '사기'로 오판 (False Positive)하면 고객 경험이 최악이 될 텐데요."

✓ 보통 사기로 짐작되는 고객을 '차단(1)' 또는 '통과(0)'로 결정하지 않습니다.

ML이 예측한 '확률 점수'를 활용해 고객 경험을 다르게 설계합니다.

모델 예측 확률 (Risk)	위험도	분석적 대응	비즈니스 임팩트
0% ~ 50%	낮음	정상 통과	마찰 없는 고객 경험
50% ~ 80%	중간	선제적 경고 / 추가 인증	경미한 사기 방지
80% 이상	높음	거래 즉시 차단 / 수동 검토	치명적인 사기 방어

★ 보통 현업의 Fraud 모델은 '차단'이 목적이 아니라, '**위험도를 관리**'하는 것이 목적입니다. '모델의 확률'을 **비즈니스 정책**으로 변환해야 합니다.

[Case 3] 개인화 (Personalization)

"Y값이 있는데 어떻게 '개인화'에 써야 할까?"

PM의 요청: "이메일 마케팅 효율이 떨어집니다. '짧은' 이메일이 좋은지, '긴' 이메일이 좋은지 모르겠어요. **고객별로 최적의 이메일**을 보내고 싶습니다."

Y값 정의: $Y = \text{이메일 클릭 여부 (1/0)}$

기존 이메일 클릭률: 2% (읽은 사람 중 누른 사람 비율)

Tip 1: '평균 최적' vs '개인 최적'

1. 단순 분석 (EDA)의 한계

분석: "'짧은 이메일'의 클릭률(3%)이 '긴 이메일'(1%)보다 **평균적으로** 낮네요."

액션: "모든 고객에게 '짧은 이메일'을 보냅니다."

! 문제: '긴 이메일'을 더 선호하는 특정 고객을 놓치게 됩니다.

2. ML을 활용한 '개인 최적화' (Supervised)

★ ML은 '각 개인에게 가장 성공 확률이 높은 정책이 무엇인지' 시뮬레이션하고 선택하게 해 줍니다. (긴 이메일 / 짧은 이메일)

Tip 2: '개인 최적화'를 위한 X값(피처) 설계

ML이 '개인 최적화'를 하려면 '바꿀 수 없는 고객 특성'과 '바꿀 수 있는 정책'을 모두 활용합니다.

피처 (X)	이메일 예시] X값 후보군
유저 특성 (수정 못 함)	구매 이력 (i.e., 없음, 낮음, 높음), 접속 국가 , 가입 기간 , 주 사용 기기
정책 (수정 가능)	이메일 길이 (i.e. 짧음/길), 발송 시간 (i.e. 오전/오후/밤), 발송 요일 (i.e. 주중/주말)

ML 시뮬레이션:

고객A(10대, 남성)에게는 **짧은 이메일, 오전 발송** → 클릭 확률 **5%**

고객A(10대, 남성)에게는 **길 이메일, 오전 발송** → 클릭 확률 **1%**

고객A에게는 '짧은 메일, 오전' 정책을 적용합니다. (B 고객은 반대일 수 있습니다.)

Tip 3: 모델 예측의 '현실 보정'

 **Devil's Advocate:** "모델이 '클릭 확률 90%'라고 예측했는데, 실제로 90%가 클릭할까요? 우리 모델의 정밀도(Precision)가 5%밖에 안 되는데요?"

모델의 예측값(Probability)은 '실제 기대값'이 아닙니다.

현업 분석가는 모델의 **Confusion Matrix**을 반영하여 예측값을 현실에 맞게 **보정**해야 합니다.

- **[모델 예측]:** "A 고객, 클릭 확률 80%" → **이대로 믿으면 안 됨!**
- **[모델 오차]:** (Test 데이터 기준)
 - (1) 모델이 '클릭(1)'이라고 예측했을 때, **실제로 클릭했을 확률 (정밀도, Precision) = 5%**
 - (2) 모델이 '클릭 안함(0)'이라고 예측했지만, **실제로 클릭했을 확률 (False Omission Rate, FOR) = 2%**

Tip 3: 모델 예측의 '현실 보정' (예시)

[모델 예측] "A 고객, 클릭 확률 80%"

- 모델이 1(클릭할거다)이라고 예측할 확률 = 80%
- 모델이 0(클릭안할거다)이라고 예측할 확률 = 20%

이 고객은 80% 확률로 '클릭(1) 예측 그룹'에 속하고,
20% 확률로 '클릭 안 함(0) 예측 그룹'에 속한다는 뜻입니다.

[현실 보정 계산]:

$$\begin{aligned} & (\text{모델이 1이라고 예측할 확률} \times \text{Precision 5\%}) + (\text{모델이 0이라고 예측할 확률} \times \text{FOR 2\%}) \\ &= (0.8 \times 0.05) + (0.2 \times 0.02) \\ &= 0.04 + 0.004 = \text{약 4.4\%} \end{aligned}$$

★ 모델이 80%를 예측해도 우리의 기대치는 4.4%입니다 (기존 2% 대비 2배 이상이므로 여전히 가치 있음). A/B 테스트의 ROI를 '보정된 기대치'로 계산하여 보고해야 합니다.

5회차 요약

1. **[Y값 설계] Actionable**한 Y값을 정의하여 **모델의 목적지**를 설정합니다. (LTV 예시)
2. **[모델 검증]** 분석목적에 맞게 여러 평가지표로 검토하여 모델을 평가하고, Data Leakage를 피해야 합니다. (Fraud 예시)
3. **[ML 활용]** '평균'이 아닌 '개인 최적'의 정책을 선택하고, 그 가치를 '현실 보정'하여 증명합니다. (Personalization 예시)

퀴즈타임

Q&A

Next Session

6회차: Case Study를 통한 분석적 사고력 훈련