

분석적 사고력 훈련

6회차: Case Study를 통한 분석적 사고력 훈련

| 이준수 튜터

오늘은 5가지 분석 실전 케이스를 통해 '분석가의 뇌'를 훈련합니다.

5회차 복습

1. **[Y값 설계] Actionable**한 Y값을 정의하여 **모델의 목적지**를 설정합니다. (LTV 예시)
2. **[모델 검증]** 분석목적에 맞게 여러 평가지표로 검토하여 모델을 평가하고, Data Leakage를 피해야 합니다. (Fraud 예시)
3. **[ML 활용]** '평균'이 아닌 '개인 최적'의 정책을 선택하고, 그 가치를 '현실 보정'하여 증명합니다. (Personalization 예시)

분석적 사고력 훈련

1. 분석의 '목적' 찾기 (문제 정의)
2. 가설을 세우고 테스트 가능한 형태로 변형하기
3. 문제의 원인을 찾는 방법 (Funnel / Cohort / Segmentation)
4. 결과 설명하는 방법 (스토리텔링)
5. 현업의 ML 모델링 방법
6. **Case Study**를 통한 분석적 사고력 훈련

[Case 1] 평균 vs. 중앙값 (통찰)

"인스타그램 유저의 '일일 평균 좋아요 수'가 '중앙값'보다 클까요, 작을까요?"

[Case 1] 평균(Average)이 중앙값(Median)보다 큼

- 중앙값 (Median)

대부분의(50%) 사람들은 '눈팅'을 합니다. (i.e. '좋아요' 0-1개)

- 평균 (Average)

'소수의 인플루언서/헤비 유저'가 전체 값을 끌어올립니다.

★ "평균을 올리겠다"는 목표(헤비 유저 타겟)와

"중앙값을 올리겠다"는 목표(라이트 유저 타겟)는 **완전히 다른 비즈니스 전략**입니다.

[Case 2] 당근 (전략)

상황: "당근(Karrot) 앱을 개선해야 합니다. 무엇을 해야 될까요?"

너무 General합니다.

'분석적 사고'는 이 문제에 대한 Decomposition에서 시작합니다. (3회차 복습)

[Case 2] 수요(Demand) vs. 공급(Supply)

당근과 같은 Marketplace의 성공은 보통 '거래 수'입니다. 거래 수를 쪼개 봅시다.

거래 수 = 수요 (Demand) × 공급 (Supply)

거래 수 = 방문수 × 구매 전환율

(Demand) 수요: "얼마나 많은 사람이 당근에 방문을 해서 물건을 찾는가?"

(Supply) 공급: "방문한 사람이 원하는 물건을 찾고 실제로 구매하는가?"

분석가의 질문: "우리의 '병목'은 수요인가요, 공급인가요?"

[Case 2] 분석 방향 결정

1. 공급(Supply) 점검

- **분석:** "방문한 유저들이 원하는 것을 찾고 있는가?"
(i.e. '검색 → 채팅' 전환율, '검색 실패' 키워드 분석)
- **결론:** 만약 공급이 부족하다면(전환율이 낮다면) 방문자를 늘려봤자 거래 수는 적게 오릅니다.
→ 공급(제품 구색, 검색 품질) 개선이 먼저입니다.

2. 수요(Demand) 점검

- **분석:** "공급이 충분하다면, 어떻게 방문자를 늘릴까?"
(i.e. '알림/광고 → 방문' 광고 유입 CTR 분석)
- **결론:** 광고 유입 CTR이 낮으면 광고 '메시지'를 바꾸고 높으면 검색 '노출'을 늘립니다.

★ 분석가는 '**문제를 쪼개어**' 리소스 투입의 우선순위(공급 vs 수요)를 정해야 합니다.

[Case 3] iOS vs. Android (진짜 원인 찾기)

상황: "데이터를 보니 카카오톡 iOS 유저의 70%가 인스타그램을 쓰는데, Android 유저는 35%만 씁니다. **왜 이런 차이가 날까요?**"

✗: "iOS 유저가 인스타그램을 더 좋아하나 봅니다."

✓ 분석적 사고: "**OS가** 차이의 '진짜 원인'일까요, 아니면 다른 변수의 **Proxy**일까요?"

■ [Case 3] 분석적 사고: 원인인가, Proxy 인가? (1/2)

가설: OS는 진짜 원인이 아니다. "국가, 연령, 소득" 같은 변수의 Proxy일 것이다.

(i.e. "소득이 높은 젊은 사람들은 (1) iOS를 많이 쓰고 (2) 인스타그램도 많이 쓴다. → 'OS'가 아니라 '연령 및 소득'이 진짜 원인 아닐까?")

검증 방법

1. **ML 모델링:** Decision Tree 모델을 학습해 "인스타그램 사용 여부(Y)"를 예측하게 합니다.
2. **질문:** 모델이 **가장 먼저 쪼개는 변수**가 'OS'인가요, 아니면 '연령'인가요?
3. **또는:** 'OS 변수'를 뺀 모델과, 포함한 모델의 **성능이 거의 같다면?**
→ OS는 중요하지 않은 변수(프록시)입니다.

■ [Case 3] 분석적 사고: 원인인가, Proxy 인가? (2/2)

1. 만약 'OS'가 실제 프록시(Proxy)였다면?

- **분석 결과:** Decision Tree가 '연령', '국가'를 먼저 Decompose합니다.
- **결론:** 차이의 원인은 OS가 아니라 '연령별/국가별' 선호도 차이입니다.

2. 만약 'OS'가 진짜 원인이었다면?

- **분석 결과:** 다른 변수를 통제해도, 여전히 Android의 사용률이 낮습니다.
- **결론:** OS 자체가 원인입니다. → Android 앱의 근본적인 문제(버그, 로딩 속도, UX)를 조사해야 합니다.

★ 분석가는 상관관계($A=B$)를 인과관계($A \rightarrow B$)로 착각하지 않고,
'진짜 원인'을 찾기 위해 스스로가 Devil's Advocate가 되어야 합니다.

[Case 4] 티빙의 CC 정보 (검증)

상황: "현재 티빙 30일 무료 체험은 '신용카드(CC) 정보'를 입력해야 합니다. 만약 'CC 정보 없이' 가입하게 하면 어떨까요? **이 A/B 테스트 할 가치가 있나요?**"

전체 구독 전환율 = 무료 체험 전환율 × 유료 구독 전환율

무료 체험 전환율: 무료체험 시도하는 비율 (%)

무료 체험 전환율: 무료체험자 중 구독 전환 비율 (%)

CC 정보를 없애면 '무료 체험 전환율' ↑ '유료 구독 전환율' ↓

[Case 4] '비싼 테스트' 시작하기 전에 '타당성' 보기

A/B 테스트는 비쌉니다.

EDA로 이 테스트의 성공 가능성을 미리 탐색해야 합니다.

(탐색): 현재 데이터에서 **"의지가 낮은 고객"**, 즉 'CC 없는 신규 유저'와 가장 유사한 그룹을 먼저 찾습니다. (i.e. 가입 후 '즉시 구독 취소'한 유저)

[Case 4] 의사결정 Framework

(결정 A): 만약 이 '즉시 취소' 유저들이 30일 뒤 '재구독'을 많이 한다면?

→ "테스트 GO!" (우리 구독 프로덕트는 의지 낮은 고객도 설득할 힘이 있다.)

(결정 B): 만약 이들이 전혀 재구독하지 않는다면?

→ "테스트 HOLD!" (구독 프로덕트 개선이 먼저다!)

★ 분석가는 '비싼 테스트'를 하기 전에 데이터에서 '미래를 예측할 Proxy'를 찾아내어 가설의 성공 가능성을 미리 검증해야 합니다.

Case 5: 버그와 스파이크 (역설적 해석)

상황: "버그로 인해 '모바일 웹' 접속이 중단되었습니다.

그런데 핵심 지표인 '**1인당 일일 참여도**'가 급등했습니다. **왜일까요?**"

분석적 사고: '1인당 참여도' = (Action 수 / User 수) 입니다.

분자 분모 둘 다 확인해야 합니다.

[Case 5] 분석적 사고: '착시'인가, '기회'인가?

해석 1 (나쁜 소식 - 분모 효과)

- '모바일 웹' 유저들은 원래 '참여도가 낮은(i.e. Action 2회)' 유저들이었습니다.
 - 이들이 분모(총 유저)에서 빠지니, '참여도 높은(i.e. Action 10회)' 앱 유저들만 남아 '평균'값이 올라가는 '통계적 착시'가 발생했습니다.
- > 결론: 전체 유저는 줄었으므로 사실상 악재

[Case 5] 분석적 사고: '착시'인가, '기회'인가?

해석 2 (좋은 소식 - 분자 효과)

- '모바일 웹' 유저들이 불편해서 '모바일 앱(참여도 높음)'을 새로 다운로드했습니다.
- 그 결과 분모(총 유저)는 비슷하지만 'Action(분자)'이 '진짜로' 증가했습니다.
-> 결론: 버그가 고객의 행동을 긍정적으로 바꿈

★ 분석가는 '착시'와 '진짜 원인'을 구분하여, "모바일 웹을 아예 끄고 앱 다운을 유도하자"는 올바른 '다음 액션'을 제안해야 됩니다.

퀴즈타임

Q&A