



## 심화프로젝트 8조 (왕십리 팀) 최종 발표 스크립트

### Part 1. 오프닝 및 문제 정의

- **[Slide 1: 오프닝]** "올라! 투두 뱅! 안녕하세요, 데이터 분석 프로젝트 발표를 맡은 왕십리 팀입니다. 저희 프로젝트의 주제는 '아마존에도 로켓배송이 갈까요?'라는 질문에서 시작되었습니다. 현재 로켓배송 서비스 지역이 아닌 브라질 시장의 데이터를 바탕으로, 배송과 고객 만족도의 관계를 분석한 결과를 지금부터 공유해 드리겠습니다."
- **[Slide 2: 목차]** "오늘 발표 목차는 다음과 같습니다. (손짓으로 화면을 가리키며 가볍게 넘어가기)"
- **[Slide 3: 핵심 결론 요약]** "세부 내용에 앞서 핵심 결론을 먼저 짚고 넘어가겠습니다. 데이터 분석 결과, 리뷰 스코어가 급락하는 것을 막기 위한 '골든타임'은 딱 3일이었습니다. 예상 배송일보다 3일을 초과하여 지연될 경우 스코어는 급락하므로, 지연 방어의 핵심은 판매자가 유일하게 통제 가능한 '출고 시간 단축'에 있습니다."
- **[Slide 4 ~ 6: 배경 이해]** "브라질은 남미 최대 이커머스 시장이지만, 넓은 국토 탓에 물류 인프라 격차가 큼니다. 이로 인해 배송 속도는 곧 리뷰, 재구매, 클레임으로 직결됩니다. 분석 대상인 Olist는 브라질의 전자상거래 플랫폼으로, 판매자가 통제할 수 있는 영역이 매우 한정적입니다."
- "상품 품질이 뛰어나도 배송에서의 부정적 경험이 전체 스코어를 훼손하고 있었으며, 이는 곧 '리뷰는 매출'이라는 핵심 문제로 이어집니다. 따라서 판매자가 취할 수 있는 구체적인 액션을 제안하고자 합니다."

### Part 2. Data & KPI

- **[Slide 7 ~ 8: 데이터 구조]** 다음은 데이터와 KPI에 대해 설명드리겠습니다.
- "저희는 2016년부터 2018년까지의 Olist 브라질 전자상거래 데이터를 활용했습니다. Orders 테이블에서 타임스탬프를 추출해 지연 일수를 계산했고, 이 외에도 가격, 운송비, 리뷰 스코어, 위도 및 경도, 카테고리 등의 데이터를 유기적으로 연결하여 분석에 활용했습니다."
- **[Slide 9: 데이터 전처리]** "분석 목적에 맞게 방대한 원본 데이터를 정제했습니다. 타임스탬프 오류 제거, 배송 완료 데이터 추출, 결측치 및 중복 데이터 처리, 위경도 평균값 병합 등을 거쳐 최종 109,294건으로 압축했습니다."
- **[Slide 10: 파생 변수 생성]** "깊이 있는 인사이트 도출을 위해 승인, 출고, 실제 배송 소요일 및 지연 일수 등의 수치형 파생 변수를 생성했습니다. 특히 지연 일수를 세부 구간으로 나누고, 지연 여부를 이진 변수로 만들었으며, 물리적 거리를 범주화하여 머신러닝 모델의 기반을 다졌습니다."

### Part 3. EDA 분석 & 시각화 [핵심 파트]

- **[Slide 12: 전반적 분포]** "이제 본 프로젝트의 첫 번째 핵심인 EDA 분석 결과를 말씀드리겠습니다. 전체 분포를 보면 리뷰 5점이 5만여 건으로 가장 많았고, 그 다음으로 4점, 반면 1~3점은 비교적 적은 수를 차지하는 불균형 데이터 양상을 보였습니다. 상위 5개 주의 카테고리 비중을 살펴보면 화면과 같이 세 가지 카테고리에 주문이 집중되어 있었습니다." **배송소요일과 지연일수의 분포도 같이 확인하였습니다.**
- **[Slide 13: 계절성 요인]** "월별 통계를 분석해 보니, 거래량의 변동보다 배송 소요일의 '계절성'이 훨씬 중요한 변수였습니다. 카니발, 블랙프라이데이, 크리스마스 등 연말연시 이벤트 시기에 배송 소요일이 평균 14~16일까지 길어지는 패턴을 확인했습니다."
- **[Slide 14: 배송 관련 지표와 리뷰에 미치는 영향]** 다음은 배송과 관련된 다양한 시간 지표들이 리뷰 스코어에 어떤 영향을 미치는지 시각화했습니다. 결론적으로 전체 배송 속도를 높이는 것도 중요하지만, 고객 만족도 방어를 위해 관리해야 할 핵심 변수는 지연 배송 방지임을 확인할 수 있었습니다.
- **[Slide 15: 물류 지표와 리뷰의 상관관계]** "물류 지표가 길어질수록 평균 리뷰 스코어는 점진적으로 하락했습니다. 특히 지연 일수 그래프를 보시면, 지연이 발생하기 시작하는 '0 지점'부터 리뷰 스코어가 가파르게 급락하는 것을 명확히 볼 수 있습니다. 상관관계 분석 결과에서도, 배송 소요일(-0.22)이 지연 일수(-0.15)나 출고 소요일(-0.11)보다 리뷰 스코어와 더 강한 상관관계를 보였습니다."
- **[Slide 16 ~ 18: 지연 유무와 골든타임]** "하지만 전체 배송 기간의 단순한 길이보다 고객 경험에 훨씬 더 결정적인 타격을 입히는 것은 바로 **\*\*지연 유무\*\***였습니다. Mann-Whitney U 통계 검정 결과, 배송 지연이 발생한 그룹은 정상 배송 그룹에 비해 평균 리뷰 점수가 무려 1.75점이나 급락하는 매우 유의미한 악영향을 보였습니다.
- 데이터를 지연 그룹과 정시 도착 그룹으로 나누어 조금 더 깊이 파고들어 매우 흥미로운 사실을 발견할 수 있었습니다. 지연 그룹 중 일부는, 정시 도착 그룹보다 '실제 물리적인 배송 소요일'이 더 짧았습니다. 즉, 고객이 물건을 더 일찍 수령했음에도 불구하고 '약속된 예정일보다 늦었다'는 사실 그 자체만으로 리뷰 점수가 낮게 나타난 것입니다. 반대로, 안내되는 '예상 배송일' 자체를 길게 잡는 것은 리뷰 점수 하락에 큰 영향을 주지 않았습니다. 앞서 구한 스피어만 상관계수에서도 -0.056이라는 매우 미미한 수치가 이를 뒷받침합니다.
- 그렇다면 지연이 불가피하게 발생했을 때, 점수를 그나마 방어할 수 있는 **\*\*골든타임\*\***은 언제까지일까요? 조기 및 정시 배송 시 4점대를 안정적으로 유지하던 점수는, 1~3일 지연 시 평균 3.68점으로 어느 정도 방어되는 선에 머물렀습니다. 하지만 지연이 4~6일 차로 접어드는 순간 점수는 2.44점으로 크게 꺾이고, 10일 이상 지연될 경우 1.70점이라는 치명적인 급락을 보였습니다.
- 결론적으로, 물리적인 배송 소요일이 짧더라도 '안내된 예정일보다 늦었다'는 사실 자체가 고객의 리뷰 스코어에 훨씬 치명적인 악영향을 미친다는 것을 데이터로 명확히 확인했습니다. 반면 예상 배송일 자체를 넉넉하게 잡는 것은 리뷰에 큰 악영향을 주지 않았습니다.
- **[Slide 19 ~ 20: 출고 속도와 만족도]** "지연을 방어하려면 판매자가 어떻게 해야 할까요? 출고가 1~3일일 때 지연 발생률은 7.1%였으나, 6일 이상 지연되면 발생률이 18.6%로

급증했습니다. 출고 준비가 길어질수록 고객 만족 점수는 뚜렷하게 지속 하락했습니다. 1점짜리 부정 리뷰는 택배 소요일과 판매자 준비 일수 모두 가장 길었던 반면, 5점 리뷰는 전 구간이 가장 짧았습니다."

- **[Slide 21 ~ 23: 카테고리별 특성]** "상품 카테고리별로 보면, 'Home Interior' 카테고리가 평균 배송 13.5일, 지연률 11% 이상으로 리스크가 가장 큰 'Critical Risk Area'에 단독 위치했으며 ,
- 서브 카테고리 평균 점수는 Books & Media는 4.46점으로 가장 높았고,
- Home Interior는 역시나 3.81점으로 가장 낮았습니다.

## Part 4. 예측 모델 & 결과 분석 [핵심 파트]

- **[Slide 24 ~ 25: 이진 분류 모델 설계]** "다음으로 두 번째 핵심인 머신러닝 예측 모델입니다. 저희는 글로벌 표준이자, 스파르타 다면 평가에서도 쓰이는 'NPS 지표'의 원리를 모델에 차용했습니다. 이를 환산해 0~3점은 부정, 4~5점은 긍정 리뷰로 예측하는 이진 분류 모델을 설계했습니다."
- **[Slide 26: 파이프라인 설계]** "타겟 변수의 불균형을 해결하기 위해 'Stratify' 조건으로 세트를 분할하여 데이터 누수를 차단했고, 수치형 변수 대치와 범주형 변수의 One-Hot 인코딩을 병렬 변환하는 자동화 전처리 파이프라인을 꼼꼼히 구축했습니다."
- **[Slide 27: 최적 모델 선정]** "트리 기반 앙상블 모델들을 후보군으로 두고 하이퍼파라미터 튜닝을 진행했습니다. 비즈니스 목적상 고객의 이탈을 막기 위해 '부정 리뷰'를 찾아내는 것이 가장 중요하므로, '부정 recall' 값이 0.66으로 가장 높게 측정된 LightGBM Classifier를 최종 선정했습니다."
- **[Slide 28 ~ 29: 예측 성능 및 안정성]** "Threshold Tuning을 통해 임계값을 약 0.59로 최적화했습니다. 이 모델을 적용하면, 배송 완료 전 작성될 부정 리뷰를 66% 확률로 미리 탐지해낼 수 있습니다. 즉, 판매자가 선제적으로 대응할 수 있는 강력한 무기가 생긴 셈입니다.
- 또한 Logloss 기준으로 훈련 곡선을 시각화해 과적합을 지속적으로 탐지하며 안정적으로 학습을 마쳤습니다."
- **[Slide 30: 분류 모델 성능 평가]** Confusion Matrix 결과와 성능 지표를 보겠습니다. 이 모델은 판매자의 리스크를 최소화하기 위해 개발한 분류 모델의 성능 평가 결과입니다. valid와 test의 성능 차이가 없으므로 과적합을 방지하였고 우리의 핵심 목표인 판매자에게 악영향을 미칠 수 있는 부정 클래스 탐지에 대해서는 66% 수준의 유의미한 탐지 성능을 보여주고 있습니다.
- **[Slide 31: 피처 중요도 분석 - 핵심 인사이트]** "이 모델에서 가장 흥미롭고 중요한 결과는 피처 중요도(Feature Importance)에서 발견되었습니다. 배송 불만의 가장 직접적 원인이라 예상했던 '지연 일수(1477점)'보다, 고객이 지불한 '배송비(2037점)'와 '상품 가격(1835점)'이 리뷰 스코어에 훨씬 더 큰 영향을 미쳤습니다. 즉, 고객은 지불한 총비용이 높을수록 배송 서비스 품질에 훨씬 더 간소한 잣대를 들이댄다는 심리가 데이터로 완벽히 증명된 결과입니다."

## Part 5 & 6. 전략 제안 및 KPT 회고

- **[Slide 32: 전략 제안 (차별화 액션 플랜)]** "이러한 데이터 인사이트를 바탕으로 판매자분들께 4가지 맞춤 전략을 제안합니다. 첫째, 예상 배송일을 기존보다 여유롭게 설정해 심리적 지연을 막습니다. 둘째, 물류 집중기나 먼 배송지의 경우 사전에 안내 문자를 발송합니다. 셋째, 피쳐 중요도에서 보았듯 비용에 예민한 높은 배송비 지불 고객에겐 프리미엄 포장 등 차별화된 서비스를 제공하고, 넷째, 고액 상품 구매자에겐 무료배송 프로모션을 진행하여 엄격해진 심리적 보상 기준을 선제적으로 충족해야 합니다."
- **[Slide 33 ~ 35: KPT 회고 및 비전]** "마지막으로 본 프로젝트를 통한 저희 팀의 KPT 회고입니다. 팀원 간 비즈니스 목표를 지속적으로 맞추고 코드를 공동 설계한 점은 훌륭한 Keep 포인트였습니다. 반면 1:N 테이블 병합 과정과 모델 과적합 튜닝 과정은 쉽지 않은 Problem이었습니다. 향후에는 고유 ID 기반 맞춤 분석과 텍스트 NLP 분석을 Try 해보고자 합니다."
- **[Slide 36 ~ 38: 소감 및 마무리]** "개인적인 소감과 협업 과정을 되돌아보았을 때, 이번 심화 기간 동안 학습한 통계와 머신러닝을 프로젝트에 녹여내려 치열하게 고민했던 시간이 떠오릅니다. 직접 통계 검정 방법을 적용해 보고, 머신러닝 모델 파라미터 값을 일일이 수작업으로 맞춰보는 일명 '인간 튜닝'을 진행하며 지식을 제 것으로 체화했던 이 과정이 가장 기억에 남습니다. 해당 자료의 참고 문헌은 보시는 바와 같습니다. 데이터로 끊임없이 증명하고 성장하는 우리 왕십리 팀의 행보는 계속됩니다. 이상으로 발표를 마치겠습니다. 감사합니다!"