

스파르타

왕십리에서 만나요

브라질


아마존에도 로켓배송이 갈까요?



현재 서비스 지역이 아닙니다

PARK HYELIM SONG WONWOO KWON NAMHUN KIM YOONSEO

Index



Conclusion

3일

리뷰 스코어 급락 골든타임

자연 방어의 핵심은 출고 시간 단축

- ✓ **골든타임 3일**
예상 배송일보다 3일 초과할 경우
리뷰 스코어는 급락
- ✓ **판매자의 통제권**
‘상품 출고 소요일’은 직접적인 통제 및 단축 가능
- ✓ **고객 조건에 따른 차별화 전략**
상품가, 배송비, 배송지와의 거리 등을 고려하여
맞춤별 고객 관리

Part1



BACK GROUND



배경 이해 및 문제 정의

산업 배경

브라질 — 남미 최대 이커머스 시장
국토가 넓고 주 간 물류 인프라 격차 심함

구매 의사결정 요소 —
가격 비교, **배송 속도**, 모바일 쇼핑 경험 등

배송 경험 —
리뷰, 재구매, 클레임에 직접적 영향

Olist 기업 배경

브라질 전자상거래 솔루션 플랫폼

다채널 판매 연결 —
여러 마켓플레이스 동시 입점 · 상품노출

주문, 재고, 배송, 리뷰 관리 **통합 운영**

판매자 배경

리뷰 스코어는 구매 결정에 직접적 영향

배송 과정 중 **판매자 통제 영역** —
상품출고 시점, 포장 방식, 배송 옵션 선택,
무료배송 정책 등

문제 정의



리뷰는 곧 매출

구매자의 리뷰 스코어는
다음 소비자의 구매 전환율을 결정



배송 x 만족도 관계

상품 자체의 품질이 뛰어나더라도
배송과정에서의 부정적경험(지연/파손)이
전체 스코어를 훼손하는 현상 발생



배송 서비스
개선을 위한
판매자의 액션제안


Part 2



DATA & KPI



데이터 이해 & KPI 정리



2016 – 2018년 Olist 브라질 전자상거래 데이터

핵심 KPI

delay_days

(delivered_customer_date – estimated_delivery_date)

Orders	order_purchase_timestamp order_approved_at order_delivered_carrier_date order_delivered_customer_date order_estimated_delivery_date
Orders_items	price freight_value
Reviews	review_id review_score
Customers	customer_zip_code_prefix customer_state
Sellers	seller_zip_code_prefix seller_state
Geolocations	geolocation_zip_code_prefix geolocation_lat geolocation_lng
Category	product_category_name product_category_name_english

전처리

Orders

- 타임스탬프 오류치 23건 제거
- 배송 '완료'된 데이터만 추출 (99,418건 → 96,455건)
- delivery date 결측치 23건 제거

Reviews

- 리뷰코멘트 결측치 → 'None'
- 동일 order_id에 대한 중복 review는 최신 데이터만 놔두고 중복 제거

Geolocation

- 동일 zip-code 기준 중복 위도/경도 데이터 → mean (738,332건 → 19,015건)
- Sellers, Customers 테이블에 zip-code 기준으로 merge

Items

- 동일 order_id에 대한 복수 상품 주문은 집계 없이 모두 고유 행으로 보존

결측치

- review_score의 결측치 제거 (110,123건 → 109,296건)
- customers, sellers의 위도/경도 결측치 : city 별 위도/경도 최빈값으로 대체
- 대체 후에도 남은 결측치 49건은 추후 '거리' 파생컬럼 생성 시 행 제거

◆ 파생컬럼 ◆

컬럼명	타입	설명	비고
approved_days	int64	승인 소요 일수 (approved - purchase)	
dispatch_days	int64	출고 소요 일수 (delivered_carrier - purchase)	
delivery_days	int64	실제 배송 소요 일수 (delivered_customer - purchase)	
delay_days	int64	지연 일수 (delivered_customer - estimated_delivery)	조기 / 정시 / 1-3일 지연 / 4-6일 지연 / 7-9일 지연 / 10일 이상 지연





컬럼명	타입	설명	비고
is_delayed	int64	지연 여부 (delay_days > 0)	
main_category	str	카테고리 대분류	
sub_category	str	카테고리 중분류	
distance_km	float64	판매자와 구매자 사이 거리	머신러닝 모델 훈련시 범주화
corss_state	int64	판매자와 구매자의 지역이 다른지 여부	

Part 3



◆ PREPROCESSING & VISUALIZATION ◆

EDA 분석 & 시각화

데이터 분포 파악




월·요일 별 통계량




- ✓ 배송소요일에는 거래량보다 계절성이 중요한 변수
- ✓ 브라질의 연말연시 행사
 - 신년 1월
 - 카니발 2월
 - 독립기념일 9월
 - 블랙프라이데이 11월
 - 크리스마스 12월
- ✓ 월별 리뷰 스코어에는 눈에 띄는 차이 없었음

EDA 분석 & 시각화




EDA 분석 & 시각화



✓ 배송소요일과 리뷰 스코어
약한 음의 상관관계

✓ 지연일 / 출고일보다 배송소요일이
리뷰스코어와 비교적 강한 상관관계



EDA 분석 & 시각화




	U_val	alternative	p_val	RBC	CLES
MWU	126952784.0	two-sided	0.0	-0.533543	0.233228


- ✓ Mann-Whitney U 검정 결과
배송 지연이 발생하는 것만으로도
고객 경험에 부정적 영향
- ✓ 지연이 발생한 주문일 경우
비지연 주문 대비
평균 리뷰 점수 45% 하락
- ✓ 배송 소요일보다
'지연 유무' 관리가 리뷰 스코어
하락을 방어하는 핵심 KPI

EDA 분석 & 시각화





EDA 분석 & 시각화






✓ Mann-Whitney U 검정 결과
지연배송의 출고 소요일이
정상/조기배송보다 크다

✓ 다만 운송기간과 배송지연의
상관관계가 더 크게 작용함


	U_val	alternative	p_val	RBC	CLES
MWU	353887641.0	two-sided	0.0	0.300274	0.650137


EDA 분석 & 시각화





EDA 분석 & 시각화





Part 4



MACHINE LEARNING



예측 모델 & 결과 분석

NPS 지표

고객 만족도를 평가할 때
세계적으로 가장 널리 쓰이는 표준 지표

- 스파르타 다면 평가에서도 사용
- NPS 원본 기준 (10점 만점)
 - 0~6점 : 비추천 및 이탈 고객
 - 7~8점 : 중립 고객
 - 9~10점 : 추천 고객
- 리뷰스코어 5점 척도 환산
 - 0~3점 : '부정' 리뷰 예측
 - 4~5점 : '긍정' 리뷰 예측

분류 모델 생성

1. 데이터 전처리 및 피처 엔지니어링

전체 행(109,294개)의 Raw Data 노이즈 정제 및
비즈니스 로직을 반영한 핵심 파생 변수 생성
(i.e. delivery_speed, total_price)

2. 계층적 데이터 분할 [Stratify=y]

타겟 변수의 불균형 분포 비율을 동일하게 유지
Train/valid/Test 세트로 분할하여
객관적 평가 기반 마련 및 데이터 누수 사전 차단

3. 전처리 파이프라인 설계

수치형 변수(SimpleImputer)와
범주형 변수(One-Hot Encoding)를
병렬로 변환하는 자동화 파이프라인 구축

4. 모델 학습 및 평가

파이프라인을 기반으로 분류 모델 학습 및
평가지표(recall, balanced accuracy 등)를 활용하여
최적화된 성능 검증

◆ 모델 최적화 ◆



트리기반 앙상블

Light GBM Classifier
XGBoost Classifier
RandomForest Classifier

CV

하이퍼파라미터 튜닝


RandomizedSearchCV
& GridSearchCV



부정 recall

Light GBM Classifier 최종 선택

LIGHT GBM CLASSIFIER 선택: NEGATIVE RECALL이 가장 높음: 0.660



NEGATIVE RECALL & BALANCED ACCURACY 의

교차점을 THRESHOLD 로 결정


THRESHOLD 측정값: 0.58997

THRESHOLD	0.59
NEG_RECALL	0.6601
BALANCED_ACC	0.6498
MACRO_F1	0.5982
ACCURACY	0.6442

예측 모델 요약

배송 완료 전, 부정 리뷰(1~3점)를 66% 확률로 탐지해낼 수 있음
 판매자는 지연이 예상되는 시점에 고객에게 선제적으로 대응함으로써
 평판 하락 방어 가능 (최적 임계값: 0.59 적용)


분류모델



LOG LOSS: 불균형 데이터에서 가중치를 크게 주는 손실함수 평가지표

**VALID SET과 TRAIN SET의
LOG LOSS를 비교하여
과적합 탐지
→ 0.0769 : 과적합 X**

분류모델



테스트셋 성능 평가

정확도: 0.6445
BALANCED 정확도: 0.6505
부정 RECALL (CLASS 0): 0.6617
F1 (MACRO): 0.5987
F1 (WEIGHTED): 0.6714

◆ FEATURE IMPORTANCE ◆

freight_value	2037
delivery_price	1925
freight_ratio	1880
delivery_distance	1849
price	1835
delivery_ratio	1756
distance_km	1686
delivery_speed	1672
delay_days	1477
total_price	1458
day_per_km	1392
expected_delivery_days	1380
order_purchase_month	1003
dispatch_days	993
delivery_days	970



FEATURE IMPORTANCE 확인 결과

배송 지연 일수(Delay_Days)보다 가격(Price) 및 배송비(Freight_Value)가 리뷰 스코어에 더 큰 영향을 미치는 것으로 나타남
즉, 구매자는 지불한 금액의 크기에 따라 기대 수준이 달라지며
총 비용이 높을수록 서비스 품질에 대한 평가 기준이 더 깐깐해짐

Part 5



STRATEGIC RECOMMENDATION



전략 제안

전략 제안


1

예상 배송 도착일을
기존보다 여유롭게 설정



2

물류 집중 기간이나
배송지가 먼 경우
문자 등으로 사전 안내



3

높은 배송비를 지불한 고객에게는
프리미엄 포장 서비스 등
차별화된 서비스 전략 마련



4

고액 상품 구매자의 경우
무료배송 프로모션 전략



Part 6



KPT 회고

REVIEW

”

KEEP

비즈니스 목표 구체화 및 재확인 과정을 통해 분석 방향 정립

코드 공동 설계로
팀원 전체의 코드 이해도가 높았음

모델 성능 개선을 위해 수업 때 배운
내용들을 다방면으로 시도

PROBLEM

다중 테이블 병합 시
동일 order_id에 1:N 관계로 연결
데이터 중복 발생 및 병합 기준(집계 /
제거) 수립의 어려움

머신러닝 모델설계와 하이퍼파라미터
튜닝에 어려움(R2 성적 저조, 과적합)을
겪어 비효율적으로 직접 튜닝

TRY

customer_unique_id를 통해 고객 개인
성향 분석 후 더 고도화된 맞춤형 고객
관리 전략 수립

텍스트 분석을 통해 리뷰 코멘트를
긍정/부정 분류에 활용
리뷰스코어 범주화에 구체적 근거 마련

Part 7



REFERENCES



참고 문헌

배경 이해

- 남미 최대 이커머스 시장: https://shopee.kr/blog/detail.php?seq=496&utm_source
- 남미 최대의 전자상거래 시장: https://www.dhl.com/discover/ko-kr/e-commerce-advice/shipping-guides-by-country/country-guide-brazil?utm_source
- 브라질 소비자 경향: https://dream.kotra.or.kr/kotranews/cms/news/actionKotraBoardDetail.doSITE_NO=3&MENU_ID=180&CONTENTS_NO=1&bbsGbn=243&bbsSn=243&pNttSn=223394
- 라틴아메리카 이커머스 신뢰 영향: https://arxiv.org/abs/1911.01280?utm_source
- 리뷰스코어와 소비자 구매결정 영향(논문1): https://www.researchgate.net/publication/387722823_The_Impact_of_Online_Reviews_and_Ratings_on_Consumer_Purchasing_Decisions_on_E-commerce_Platforms
- 리뷰스코어와 소비자 구매결정 영향(논문2): https://rsisinternational.org/journals/ijrsi/articles/impact-of-consumer-generated-online-reviews-and-ratings-on-purchase-behavior-and-sales-performance/?utm_source
- 배송 성과가 온라인 리뷰 평점에 미치는 영향(논문): https://pmc.ncbi.nlm.nih.gov/articles/PMC9115748/?utm_source

머신러닝 모델

- 긍정/부정 리뷰 분류 기준: <https://www.surveymonkey.com/learn/customer-feedback/nps-calculator/>
- 거리 파생컬럼 분류 기준:
 - <https://www.cetsp.com.br/>
 - https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2015/lei/l13103.htm

THANK YOU



왕십리 팀의 성장은 계속됩니다.

