

머신러닝 실습 5회차

이야기거리

서정욱 튜터

Base Rate Fallacy (기저율 오류)

기저율(사전 확률, Base Rate)

→ 어떤 사건이 발생할 확률을 전체적으로 바라본 기본 확률

기저율 오류란?

→ 특정 정보(추가 정보, 단서)에만 주목하고

전체 집단의 기본 확률(Base rate)을 무시해 잘못된 판단을 하는 오류.

양성 판정을 받은 5000명의 사람 중 99.98% 해당하는 사람들은

실수로 양성 판정을 받게 되는 사람들

양성 판정을 받은 사람 중 실제로 AIDS에 해당하는 사람은 0.001%

➔ 흔히 생각하는 정확도 99.9%라고 생각하면 오산!
민감도, 특이도 관점에서 생각해야

생각보다 상당수가 양성 판정을 받게 되는 셈
➔ 에이즈 자체가 극히 드문 질병이라는 점을 이해하지 못하면...

더 큰 문제는, 이 문제를 정확하게 지적해주어야 할 사람은
의사여야 할텐데...

???

1977년

하버드대학교의 의대생 20명, 인턴, 레지던트, 펠로우 20명, 주치의 20
명에게 질문

MEDICAL INTELLIGENCE | ARCHIVE



Interpretation by Physicians of Clinical Laboratory Results

Authors: Ward Casscells, B.S., Arno Schoenberger, M.D., and Thomas B. Graboys, M.D. [Author Info & Affiliations](#)

Published November 2, 1978 | N Engl J Med 1978;299:999-1001 | DOI: 10.1056/NEJM197811022991808

VOL. 299 NO. 18

"If a test to detect a disease whose prevalence is **1/1000** has a false positive rate of **5%**, what is the chance that a person found to have a positive result actually has the disease, assuming you know nothing about the person's symptoms or signs?"

"어떤 질병을 진단하는 도구가 있다. 이 질병의 유병률은 **1/1000**이고 위양성률은 **5%**이다. 만약 어떤 사람이 이 검사에서 양성 판정을 받았을 때 실제로 질병을 가진 사람일 확률은 얼마인가? (단, 그 사람의 증후나 증상에 관해서는 아무 것도 모른다고 가정한다)"

(민감도 99.9% 가정)

???

정답을 맞춘 사람은 단 11명

전체 60명 중 18.3%에 불과

‘하버드대 의사의 80%가 틀리는 문제’

**대부분의 의사들은 질병을 가진 사람의 확률을
몇 %라고 예측했을까???**

???

그전에 정답을 계산해 보면,

환자 1000명을 대상(그 중에 1명이 질병)으로 검사해본다면

위양성률이 5%니까 50명 정도가 위양성에 해당

50명 중에 1명만 질병이 있으니 -> 양성일 때 질병일 확률은 2%

가장 많이 나온 오답

95%

27명응답 (44.3%, 오답자 중 과반)

최근에 이런 연구 한번 더 함 (2014년)

하버드대학교와 보스턴대학교 및 그 협력병원의 구성원을 대상

Research Letter

Medicine's Uncomfortable Relationship With Math Calculating Positive Predictive Value

Arjun K. Manrai, AB^{1,2}; Gaurav Bhatia, MS^{1,3}; Judith Strymish, MD⁴ ; [et al](#)

» [Author Affiliations](#) | [Article Information](#)

 [RELATED ARTICLES](#)  [FIGURES](#)

참가자는 총 61명이었고, 의대생 10명, 인턴 12명, 레지던트 8명, 펠로우 6명, 주치의 24명, 은퇴한 의사 1명으로 구성


Table. Survey Respondents^a

Level of Training	No. of Respondents	
	Casscells et al ¹	Present Study
Medical student	20	10
Intern		12
Resident	20 ^b	8
Fellow		6
Attending physician	20	24
Retired	0	1
Total	60	61

61명 중 정답을 맞춘 사람은 14명(23%)

가장 인기가 많은 응답?

95% (27명 응답, 44%)



지식인 계층인 의사도 이렇게 답변을 하는데 대중들은...

→ 데이터 분석가가 필요한 이유

참고로, AIDS가 그나마 특이도가 높은편(99.9%)

검사 기법 중에는 더 낮은 특이도를 가지는 질병도 많은데...
(그러면서 유병률도 낮은...)



Base Rate Fallacy (기저율 오류)

모든 무슬림이 테러리스트는 아니다

하지만 테러리스트는 모두
(혹은 대부분)
무슬림이다

**I'M NOT SAYING ALL MUSLIM ARE
TERRORIST**

**BUT I'M SAYING ALL TERRORISTS ARE
MUSLIM**

HISTORY.COM

memegenerator.net

국내 체류 중국인(동포)들의 범죄율이 높다고?

2025.10.27 | 재외동포청 기

🔊 가 📄 목록

국적	범죄건수 (건)	체류인 구(명)	인구 1,000명당 범죄건수(건)
총계	33,052	2,507,584	13.18
중국	15,533	942,395	16.48
베트남	3,410	271,712	12.55
태국	2,567	202,121	12.70
우즈베키스탄	1,711	87,698	19.51
미국	1,658	161,895	10.24
몽골	1,173	54,846	21.38
러시아	1,124	38,369	29.29
.	.	.	.
.	.	.	.
.	.	.	.

※ 출처: 경찰청 2023범죄통계, 법무부 통계월보 2023년 12월호 (원문 별첨) 중 범죄건수 상위 7개국

"남성=성범죄 잠재적 가해자?"..."우리도 피해자!"

입력 : 2018-12-26 05:00:00 | 수정 : 2018-12-26 08:39:16

사회 : 전국

"숫컷 보니 페미네" 폭행 당한 편의점
알바생, 보청기 낀다

중앙일보 | 입력 2024.03.30 00:07 업데이트 2024.03.30 01:15

Base Rate Fallacy (기저율 오류) 해결 방법

1) 반드시 “사전 확률(Base Rate)”을 먼저 확인한다

즉, 전체 중 몇 %인지

희귀 이벤트인지

클래스 분포가 어떻게 되어 있는지
를 항상 먼저 본다.

2) 모델 평가 시 Accuracy(정확도)를 버린다

특히 불균형 데이터에서는 정확도는 아무 의미 없다.

Precision(정밀도)

Recall(재현율)

F1-score

AUC-ROC

AUC-PR (희귀 사건일 때 더 중요)

을 사용

3) Oversampling / Undersampling / SMOTE 사용

SMOTE로 synthetic sample 생성

Random oversampling

Undersampling with ensemble

4) 시뮬레이션(Test) 환경에서 기저율 반영

부정 사용자 비율이 0.1%라면
모델 테스트 데이터에도 동일하게 반영해야 함.

5) 예측 임계값(Threshold) 조정

기본 threshold(0.5) 대신 0.1·0.05 등으로 조정해서
Recall을 높여야 하는 시나리오

6) 교차 검증 시 Stratified K-Fold 사용

불균형 데이터를 균형 있게 나누기 위해
항상 "층화 K-폴드"로 수행