

머신러닝 실습 6회차

이야기 거리


서정욱 튜터

설문조사를 이용하면 일부 사람들에게만 물어봐도 된다

그런데, 표본을 조사하기 때문에 일부를 조사하는 것이 함정은 아닌가?

→ **큰 수의 법칙** 덕분에 괜찮음 (표본을 적절히 뽑기만 한다면...)

큰 수의 법칙



또한 큰 수의 법칙은 **절대적인 수**가 중요 (천명쯤?)

모집단 대비 **비율**이 중요하지 않음

표본을 뽑을 때는 무엇이 제일 중요할까?

‘무작위’

Ex) 전체 인구의 평균 나이에 관해 표본조사를 하고 싶다고 할 때
➔ 나이트 클럽 혹은 경로당에서 조사를 한다면?

이상적인 방법

모집단에 전체 구성원을 **sampling frame**으로 만들고

➔ **무작위로 선택**하여 설문 진행하기

당연히 무작위가 **왜곡**이 아예 없다는 것을 보장하지는 않음!

하지만, 왜곡이 발생할 확률을 **통제된 수준 내로** 유지가 가능
→ 그게 신뢰구간

Ex) 신뢰도 95% 수준에서 표본 평균은 총인구 평균 나이에서 ~년 내에
들 것이다

설문조사에는 과연 어떤 함정이 있을까?

선택할 답이 없는 경우

배우자 나이를 묻는데

미혼이 무응답한 경우

Vs

기혼이 무응답한 경우

자발적인 참여 과정이 필요하다는 점

특정 질문에 **대답**하지 않을 수 있거나
아예 **참여**하지 않을 수 있다


설문조사 하면 떠오르는 아주 대표적인 예시?



미국 대통령 선거
여론조사

당선자를 잘 예측하는 대중잡지

‘리터러리 다이제스트 (Literary Digest)’



우리 나라로 치면
이런 느낌?



리터러리 다이제스트

1920-30년대까지만 해도 미국 내에서 인지도가 높은 여론조사 기관

4차례의 대통령 선거가 있었는데 **모두 정확하게** 예측!

1920년 - 하딩 -> 적중

1924년 - 쿨리지 -> 적중

1928년 - 후버 -> 적중

1932년 - 루스벨트 -> 적중

100 % 적중

1936년 미국 대통령 선거



1936년
미국 대통령 선거



프랭클린 루즈벨트(민주당)



알프 랜던(공화당)

1936년 미국 대통령 선거

공화당 후보 랜던(Alfred M. Landon)이 3:2의 우세로 당선할 것을 예측

The Literary Digest

NEW YORK OCTOBER 31, 1936

Topics of the day

LANDON, 1,293,669; ROOSEVELT, 972,897

Final Returns in The Digest's Poll of Ten Million Voters

Well, the great battle of the ballots in the Poll of ten million voters, scattered throughout the forty-eight States of the

lican National Committee purchased THE LITERARY DIGEST?" And all types and varieties, including: "Have the Jews purchased

returned and let the people of the Nation draw their conclusions as to our accuracy. So far, we have been right in every Poll. Will we be right in the current Poll? That, as Mrs. Roosevelt said concerning the President's reelection, is in the 'lap of the gods.'

"We never make any claims before election but we respectfully refer you to the opinion of one of the most quoted citizens



Nominee	Franklin D. Roosevelt	Alf Landon
Party	Democratic	Republican
Home state	New York	Kansas
Running mate	John Nance Garner	Frank Knox
Electoral vote	523	8
States carried	46	2
Popular vote	27,752,648	16,681,862
Percentage	60.8%	36.5%

1936년 미국 대통령 선거

민주당 후보 프랭클린 D. 루스벨트 (Franklin D. Roosevelt) 가 **압승**

결과

531표 중 523표

유권자 투표의 62퍼센트를 얻음

48개 주 가운데 46개 주에서 승리

1936년 미국 대통령 선거

결국 리터러리 다이제스트는 **1938년** 역사속으로...

1936년 미국 대통령 선거

어떤 함정이 있었든 걸까?

1936년 미국 대통령 선거

Sampling frame으로 '유선전화 가입자 명부'를 사용함

1936년 미국 대통령 선거

1936년 당시의 미국 모습



1936년 미국 대통령 선거

1936년 당시의 한국 모습



1936년 미국 대통령 선거

당시 전화는 사치품

공화당에 투표할 가능성이 높은 **부유한** 사람들이 많이 소지

즉, 전화번호부에서 얻은 표본

➔ 공화당에 투표하려는 사람들의 비율을 과도하게 반영
(표본 선택 오류)

1936년 미국 대통령 선거

참고로 당시에 리터러리 다이제스트와 함께 여론조사를 진행한

‘갤럽’은 루스벨트를 **정확하게 예측!**

그 후로 ‘갤럽’이 미국에서 주목받기 시작~

1936년 미국 대통령 선거

‘리터러리 다이제스트’는 약 230만개의 데이터를 분석했고
‘갤럽’은 5만개의 데이터밖에 분석하지 않았지만

‘리터러리 다이제스트’는 **유선전화 가입자**를 sampling frame으로 두고
‘갤럽’은 최대한 **다양한 계층**의 유권자들에게 분산해 sampling frame
을 만들었음

데이터 개수보다 적절한 표본이 훨씬 중요하다는 예시

우리나라도 비슷한 사례가 있었음

20대 대통령 선거 여론조사

		이재명	윤석열	안철수
지지율	A	43.2%	45.0%	5.9%
	B	43.8%	36.1%	7.3%
당선가능성	A	44.7%	48.2%	2.2%
	B	46.5%	46.2%	1.0%

		더불어 민주당	국민의힘	국민의당	정의당	기타정 당	없음
정당 지지율	A	37.0%	37.6%	8.0%	4.4%	2.2%	10.7%
	B	37.2%	34.2%	3.9%	5.3%	2.0%	17.4%

우리나라도 비슷한 사례가 있었음

20대 대통령 선거 여론조사

		이재명	윤석열	안철수
지지율	ARS	43.2%	45.0%	5.9%
	전화면접	43.8%	36.1%	7.3%
당선가능성	ARS	44.7%	48.2%	2.2%
	전화면접	46.5%	46.2%	1.0%

동일한 기간(25~16),
동일한 기관(KSOI)

조사 방식만 다름

		더불어 민주당	국민의힘	국민의당	정의당	기타정 당	없음
정당 지지율	ARS	37.0%	37.6%	8.0%	4.4%	2.2%	10.7%
	전화면접	37.2%	34.2%	3.9%	5.3%	2.0%	17.4%

표본 선택 오류가 아닌 다른 의견

통계학자 **모리스 브라이슨**(Maurice Bryson)이 제시

전화기를 가지고 있는 사람 -> **투표할 가능성이 가장 큰 사람**

표본 선택 오류가 아닌 다른 의견

여론 조사를 위해 설문지를 우편으로 보냈지만
약 4분의 1인 230만 명 만이 답변을 하였음

설문지를 받고도 **무시한** 사람들이 **4분의 3정도**나 되었음
(공화당 쪽이 항상 정치 관심 많았고 투표 많이 했었음)

즉, 자발적인 참여 여부에 따른 함정

여론조사의 결과에 **bias**가 있음을 이해하지 못하면
다음과 같은 문제가...



이런 비슷한 사례

