

STATISTICS

통계 1차시: 기본 개념 이해

STATISTICAL THEORY

HYERI KANG

STATISTICS

TABLE OF CONTENTS

- ◆ Statistics 주제가
- ◆ 통계적 사고의 중요성
- ◆ 데이터의 유형

- ◆ 통계의 양대산맥: 기술통계
- ◆ 통계의 양대산맥: 추론통계
- ◆ 통계 이론 1회차 정리

STATISTICS

1. STATISTICS 주제가



HYERI KANG

2. 통계적 사고의 중요성

통계에 관한 간단한 설문조사 (중복 선택 가능)

1. 저는 통계가 싫어요.
2. 저는 통계가 어려워요.
3. 저는 통계를 몰라요.
4. 저는 통계 전공자입니다. (훗)
5. 저는 통계가 좋아요.
6. 저는 통계 성애자입니다.

2. 통계적 사고의 중요성

통계에 관한 간단한 설문조사 (중복 선택 가능)

1. 저는 통계가 싫어요.
2. 저는 통계가 어려워요.
3. 저는 통계를 몰라요.
4. 저는 통계 전공자입니다. (훗)
5. 저는 통계가 좋아요.
6. 저는 통계 성애자입니다.

STATISTICS

2. 통계적 사고의 중요성

그럼에도 불구하고 통계를 배워야 하는 이유는?

2. 통계적 사고의 중요성

방대한 양의 데이터를 요약하기 위해서

- 이커머스에 하루에 주문이 50만 건씩 적재
- 모든 주문을 하나하나 보는 건 불가능
 - 평균 주문 금액(AOV)
 - 중앙값, 분위수
 - 지역별·요일별 분산
- 같은 통계 요약치를 써서
 - “대부분의 고객은 얼마를 쓰는지”,
 - “극단적으로 큰 주문이 평균을 왜곡하고 있는지”
- 한눈에 파악
- 통계 없이는 ‘숫자는 많은데 아무 말도 못 하는 상태’

2. 통계적 사고의 중요성

보다 나은 의사결정을 위해서

- 마케팅팀 “배너 A가 배너 B보다 클릭률이 높아요!” 보고
- 이때 통계를 모르면
 - “오, 그럼 A로 가죠”
- 통계를 알면
 - 표본 수 확인
 - A/B 테스트
 - P-Value, 신뢰구간 확인
- 결과적으로
 - “이 차이는 우연일 가능성이 높다”
 - “지금은 더 실험해야 한다”
- 같은 의사결정의 근거 생성

2. 통계적 사고의 중요성

중요한 사회적 질문에 대답하기 위해서

- “사교육이 정말로 학생 성적을 올리는가?”
- 단순 평균 비교는 위험
 - 원래 성적이 높은 학생이 사교육을 더 받았을 수도 있음
 - 가정 배경, 지역, 학교 차이가 섞여 있음
- 통계를 활용해
 - 회귀 분석
 - 공변량 통제
 - 준실험 설계
- 를 적용하면
- “사교육 자체의 효과”를 분리해서 추정 가능
- 사회 이슈에 대해 감정이 아니라 근거 제시 가능

2. 통계적 사고의 중요성

기저귀 판매부터 범인 검거에 이르기까지
일을 보다 잘할 수 있는 패턴을 알아보기 위해서

- 기저귀와 맥주를 함께 사는 패턴
- 신용카드 사용 시간·지역 패턴
- 콜센터 문의가 폭증하기 직전의 신호
- 통계를 통해
 - 상관관계
 - 조건부 확률
 - 군집 분석
- 을 활용하면
- “겉으로는 안 보이던 행동 패턴”을 발견
- 데이터 분석이 ‘감’이 아니라 ‘구조’를 보는 순간

2. 통계적 사고의 중요성

사기꾼을 잡고 범인을 기소하기 위해서

- 보험 사기 탐지 시스템에서
 - 특정 병원에서만 비정상적으로 청구 금액이 큼
 - 같은 사람이 여러 사고에 반복 등장
 - 정상 고객 분포에서 벗어난 행동 패턴
- 통계적으로
 - “이 행동이 얼마나 비정상적인가?”
- 를 수치로 설명해야
 - 수사 착수
 - 법적 증거
 - 기소 가능성
- 까지 연결 가능

2. 통계적 사고의 중요성

정책, 프로그램, 약, 의료 처치, 기타 혁신의 효과를 높이기 위해서

- 신약 임상시험에서
 - 치료군 vs 대조군 비교
 - 효과 크기(Effect Size)
 - 부작용 발생 확률
- 통계를 쓰지 않으면
 - “몇 명 좋아졌어요” 수준에서 끝
- 통계를 쓰면
 - “이 약은 평균적으로 생존율을 15%p 높이며, 부작용 위험은 허용 범위”
- 같이 정책과 의료 결정을 좌우하는 숫자 생성 가능

2. 통계적 사고의 중요성

비윤리적인 목적을 위해
이런 강력한 도구를 이용하는 악당을 발견하기 위해서

- 특정 집단만 대출이 거절되는 알고리즘
- 채용 모델이 여성 지원자를 체계적으로 낮게 평가
- 여론 조작 봇 계정의 비정상적 활동 패턴
- 통계를 알면
 - 편향(Bias) 분석
 - 분포 비교
 - 이상치 탐지
- 를 통해
 - “이 시스템은 공정하지 않다”
 - “의도적 조작 가능성이 있다”
- 를 숫자로 폭로 가능

2. 통계적 사고의 중요성

통계학을 배우는 이유

- 방대한 양의 데이터를 요약하기 위해서
- 보다 나은 의사결정을 위해서
- 중요한 사회적 질문에 대답하기 위해서
- 기저귀 판매부터 범인 검거에 이르기까지 일을 보다 잘할 수 있는 패턴을 알아보기 위해서
- 사기꾼을 잡고 범인을 기소하기 위해서
- 정책, 프로그램, 약, 의료 처치, 기타 혁신의 효과를 높이기 위해서
- 비윤리적인 목적을 위해 이런 강력한 도구를 이용하는 악당을 발견하기 위해서

STATISTICS

3. 데이터의 유형



Collect data from
disparate devices

SOURCE

STATISTICS


3. 데이터의 유형



HYERI KANG

STATISTICS

3. 데이터의 유형




STATISTICS


3. 데이터의 유형



3. 데이터의 유형



3. 데이터의 유형




SOURCE

HYERI KANG

3. 데이터의 유형

- 수치형 / 양적 데이터 (Numerical 수치형 / Quantitative 양적)
 - 이산형 (Discrete): 셀 수 있는 정수값 (고객 수, 불량품 개수, 클릭 횟수)
 - 연속형 (Continuous): 측정 가능한 실수값 (키, 몸무게, 온도, 풍속)
- 범주형 / 질적 데이터 (Categorical 범주형 / Qualitative 질적)
 - 명목형 (Nominal): 순서 없는 범주 (성별, 혈액형, 지역)
 - 순서형 (Ordinal): 순서 있는 범주 (수능 등급, 만족도 등급, 선호도 순위)
 - 이진형 (Binary): 두 개의 값 (0/1 혹은 참/거짓)만을 갖는 범주형 데이터의 특수한 경우

3. 데이터의 유형



SOURCE

HYERI KANG

4 & 5. 통계의 양대산맥

Descriptive vs Inferential Statistics



Descriptive and inferential statistics are two main branches of statistics that are used to analyze and interpret data.


기술 통계

DESCRIPTIVE

Descriptive statistics is a branch of statistics used to summarize and describe the characteristics of a dataset. Descriptive statistics involves calculating summary measures, such as the mean, median, mode, range, standard deviation, variance.



VS



추론 통계


INFERENTIAL

Inferential statistics is a branch of statistics used to make inferences or predictions about a population based on a sample of data. Inferential statistics involves using statistical tests, such as hypothesis tests and regression analysis.


SOURCE

HYERI KANG

4 & 5. 통계의 양대산맥



4. 통계의 양대산맥: 기술통계



4. 통계의 양대산맥: 기술통계

기술통계 (Descriptive Statistics)

- 기술통계학 또는 기술통계는 측정이나 실험에서 수집한 자료 (data)의 정리, 요약, 해석, 표현 등을 통해 자료의 특성을 규명하는 통계적 방법
- 수집한 데이터를 정리 / 요약 / 해석 / 표현
- 이미 있는 데이터를 보기 좋게 요약 및 정리하는 것
- 목적: 흐름을 빠르게 이해하고, 의사결정하기 위함
- 예를 들어, 매출 데이터를 표 혹은 그래프로 요약 및 시각화

4. 통계의 양대산맥: 기술통계

- 위치 추정
 - 평균 (Mean)
 - 중간값 / 중앙값 (Median)
- 변이 추정
 - 표준편차와 관련 추정값들
 - 백분위수에 기초한 추정
- 데이터 분포 탐색
 - 백분위수와 상자그림
 - 도수분포표와 히스토그램
 - 밀도추정
- 이진 데이터와 범주 데이터 탐색
 - 최빈값 (Mode)
- 상관관계
 - 산점도

4. 통계의 양대산맥: 기술통계

- 위치 추정
 - 평균 (Mean)
 - 중간값 / 중앙값 (Median)
- 변이 추정
 - 표준편차와 관련 추정값들
 - 백분위수에 기초한 추정
- 데이터 분포 탐색
 - 백분위수와 상자그림
 - 도수분포표와 히스토그램
 - 밀도추정
- 이진 데이터와 범주 데이터 탐색
 - 최빈값 (Mode)
- 상관관계
 - 산점도

4. 통계의 양대산맥: 기술통계

평균

- 산술평균 (Arithmetic Mean): 데이터를 모두 더한 값을 데이터 수로 나누어 구한 평균
- 절사평균 (Trimmed Mean): 값들을 크기 순으로 정렬한 후, 양끝에서 일정 개수의 값들을 삭제한 뒤 남은 값들을 가지고 구한 평균. 정해진 개수의 극단값 (Extreme Value)을 제외한 나머지 값들의 평균
- 가중평균 (Weighted Mean): 각 데이터 값에 가중치를 곱한 값들의 총합을 다시 가중치의 총합으로 나눈 평균

4. 통계의 양대산맥: 기술통계

신혼부부 첫 집 마련형 (아파트 선호)

 마포구 거주

 예산 8억 이하

 소형 SUV 1대



차우(32)
IT 개발자(여의도)



강혜리(30)
마케팅 직장인(강남)

 희망 주거 조건


- # 아파트 선호
- # 20 ~ 30평대
- # 건물 연식 15년 이하

 희망 입지 조건

- # 성동/광진구
- # 2호선 역세권
- # 출퇴근 접근성 높은 곳

STATISTICS

4. 통계의 양대산맥: 기술통계



STATISTICS

4. 통계의 양대산맥: 기술통계



SOURCE

HYERI KANG

4. 통계의 양대산맥: 기술통계

중앙값

- 중간값 / 중앙값 (Median): 데이터를 일렬로 정렬했을 때, 한 가운데에 위치하는 값. 만약 데이터 개수가 짝수라면 그 중간값은 실제 데이터 값이 아닌 가운데 있는 두 값의 평균. 모든 관측치를 다 사용하는 평균과는 달리, 중간값은 정렬된 데이터의 가운데에 위치한 값들만으로 결정. 데이터에 매우 민감한 평균보다는 중간값이 많은 경우, 위치 추정에 더 유리.
- 특잇값 / 극단값: 특잇값은 어떤 데이터 집합에서 다른 값들과 매우 멀리 떨어져 있는 값을 의미. 다양한 정의가 있지만 정확한 정의는 다소 주관적일 수 있음. 특잇값은 데이터 값 자체가 유효하지 않거나 잘못되었다는 뜻이 아님. 물론 서로 다른 단위의 값들이 섞여 있거나, 센서에서 잘못된 값이 읽힌다면 결과적으로 이러한 에러값들이 특잇값으로 나타나기도 함. 특잇값들이 이러한 에러값들이라면, 평균은 무너가 잘못된 위치 추정을 할 수 있는 반면, 중간값은 여전히 설득력 있는 결과를 줄 수 있음. 물론 어떤 경우든 특잇값들을 확인하고 자세히 살펴본 후 분석을 진행해야 함.

STATISTICS

4. 통계의 양대산맥: 기술통계



SOURCE

HYERI KANG

4. 통계의 양대산맥: 기술통계

- 위치 추정
 - 평균 (Mean)
 - 중간값 / 중앙값 (Median)
- 변이(Variability) 추정
 - 표준편차와 관련 추정값들
 - 백분위수에 기초한 추정
- 데이터 분포 탐색
 - 백분위수와 상자그림
 - 도수분포표와 히스토그램
 - 밀도추정
- 이진 데이터와 범주 데이터 탐색
 - 최빈값 (Mode)
- 상관관계
 - 산점도

4. 통계의 양대산맥: 기술통계

표준편차와 관련 추정값들

- 편차(Deviation): 데이터가 평균에서 얼마나 떨어져 있는지 나타낸 값. 평균보다 크면 +, 평균보다 작으면 -.
- 분산(Variance): 데이터의 흩어짐을 볼 수 없는 편차의 한계를 극복하기 위해 등장한 개념. 제곱 편차 (모두 양수)의 평균.
- 표준편차(Standard Deviation): 분산의 단위가 제곱 단위라 직관적 해석이 어렵다는 문제에서 기반한 개념. 분산의 제곱근.


$$(\text{편차}) = (\text{각 변량}) - (\text{전체 평균})$$

$$(\text{분산}) = \frac{\text{편차의 제곱}(\text{편차}^2) \text{의 합}}{\text{총 변량의 개수}}$$

$$(\text{표준편차}) = \text{분산의 제곱근}(\sqrt{(\text{분산})})$$

SOURCE

4. 통계의 양대산맥: 기술통계



4. 통계의 양대산맥: 기술통계

표준편차와 관련 추정값들


- 편차(Deviation): 데이터가 평균에서 얼마나 떨어져 있는지 나타낸 값. 평균보다 크면 +, 평균보다 작으면 -.
- 분산(Variance): 데이터의 흩어짐을 볼 수 없는 편차의 한계를 극복하기 위해 등장한 개념. 제곱 편차 (모두 양수)의 평균.
- 표준편차(Standard Deviation): 분산의 단위가 제곱 단위라 직관적 해석이 어렵다는 문제에서 기반한 개념. 분산의 제곱근.

$$(\text{편차}) = (\text{각 변량}) - (\text{전체 평균})$$

$$(\text{분산}) = \frac{\text{편차의 제곱}(\text{편차}^2) \text{의 합}}{\text{총 변량의 개수}}$$

$$(\text{표준편차}) = \text{분산의 제곱근}(\sqrt{(\text{분산})})$$

4. 통계의 양대산맥: 기술통계



4. 통계의 양대산맥: 기술통계

표준편차와 관련 추정값들


- 편차(Deviation): 데이터가 평균에서 얼마나 떨어져 있는지 나타낸 값. 평균보다 크면 +, 평균보다 작으면 -.
- 분산(Variance): 데이터의 흩어짐을 볼 수 없는 편차의 한계를 극복하기 위해 등장한 개념. 제곱 편차 (모두 양수)의 평균.
- 표준편차(Standard Deviation): 분산의 단위가 제곱 단위라 직관적 해석이 어렵다는 문제에서 기반한 개념. 분산의 제곱근.

$$(\text{편차}) = (\text{각 변량}) - (\text{전체 평균})$$

$$(\text{분산}) = \frac{\text{편차의 제곱}(\text{편차}^2) \text{의 합}}{\text{총 변량의 개수}}$$

$$(\text{표준편차}) = \text{분산의 제곱근}(\sqrt{(\text{분산})})$$

4. 통계의 양대산맥: 기술통계




4. 통계의 양대산맥: 기술통계


표준편차와 관련 추정값들

- 제곱: 플러스 / 마이너스 상쇄 방지(분산 정의에 필요)
- 루트: 단위 복원 & 직관 회복 (표준편차 해석에 필요)
- 표준편차는 분산의 루트로, 현실 단위로 읽히는 변동성 지표

4. 통계의 양대산맥: 기술통계



4. 통계의 양대산맥: 기술통계



4. 통계의 양대산맥: 기술통계


표준편차와 관련 예시들

- 투자 리스크
 - 펀드 A: 평균 = 2.5%, 표준편차 = 9% (상대적으로 높은 리스크)
 - 펀드 B: 평균 = 2.5%, 표준편차 = 2%
- 입시 안정성
 - 반 A: 평균 = 75, 표준편차 = 3 (상대적으로 더 안정적)
 - 반 B: 평균 = 75, 표준편차 = 20
- 품질관리
 - 공장 A: 평균 = 10cm, 표준편차 = 0.1
 - 공장 B: 평균 = 10cm, 표준편차 = 1.5 (상대적으로 높은 불량률)
- 매출 분석
 - 평균 = 30만원, 중앙값 = 5만원, 표준편차 = 22만원 (소수의 VIP가 매출을 끌어올려 평균이 상승)

4. 통계의 양대산맥: 기술통계

백분위수에 기초한 추정

- 순서통계량(Order Statistics): 최소에서 최대까지 정렬된 데이터 값에 따른 계량형. 정렬(순위) 데이터를 나타내는 통계량
- 범위(Range): 데이터의 최댓값과 최솟값의 차이
- 백분위수(Percentile): 어떤 값들의 P퍼센트가 이 값 혹은 더 작은 값을 갖고, (100-P)퍼센트가 이 값 혹은 더 큰 값을 갖도록 하는 값
- 사분위범위(Interquartile Range, IQR): 75번째 백분위수와 25번째 백분위수 사이의 차이. 변이를 측정하는 가장 대표적인 방법



SOURCE



4. 통계의 양대산맥: 기술통계

- 위치 추정
 - 평균 (Mean)
 - 중간값 / 중앙값 (Median)
- 변이 추정
 - 표준편차와 관련 추정값들
 - 백분위수에 기초한 추정
- 데이터 분포 탐색
 - 백분위수와 상자그림
 - 도수분포표와 히스토그램
 - 밀도추정
- 이진 데이터와 범주 데이터 탐색
 - 최빈값 (Mode)
- 상관관계
 - 산점도

4. 통계의 양대산맥: 기술통계

백분위수와 상자그림

- 상자그림(Box Plot): 투키가 데이터의 분포를 시각화하기 위한 간단한 방법으로 소개한 그림. 백분위수를 이용해 데이터의 분산을 손쉽게 시각화하는 방법. 상자부분의 위쪽과 아래쪽은 각각 75%, 25% 백분위수를 의미. 중간값은 상자안에 있는 붉은 수평선으로 표시. 구레나룻처럼 위아래로 나 있는 점선이 바로 수염(Whisker)으로 데이터 전체의 범위를 나타내주는 위 아래 선들과 연결되어 있음. 수염 부분보다 더 바깥쪽에 위치한 데이터는 각자 하나의 점으로 표시.




4. 통계의 양대산맥: 기술통계

도수분포표와 히스토그램

- 도수분포표(Frequency Table): 어떤 구간(Interval) / 빈(Bin)에 해당하는 수치 데이터 값들의 빈도를 나타내는 기록. 변수의 범위를 동일한 크기의 구간으로 나눈 다음, 각 구간마다 몇 개의 변수 값이 존재하는지 보여주기 위해 사용. 구간의 크기가 너무 크면 분포를 나타내는 중요한 특징을 놓칠 수 있고, 반대로 너무 작으면 결과가 너무 쪼개져 있어서 더 큰 그림을 볼 수가 없게 됨.
- 히스토그램(Histogram): x축은 구간들을, y축은 해당 구간별 빈도수를 나타내는 도수분포표의 그림. 도수분포표를 시각화하는 방법.
 - 그래프에 빈 구간들이 있을 수 있다.
 - 구간은 동일한 크기를 갖는다.
 - 구간의 수 (혹은 구간의 크기)는 사용자가 결정할 수 있다.
 - 빈 구간이 있지 않은 이상, 막대 사이의 공간없이 서로 붙어있다.

4. 통계의 양대산맥: 기술통계



4. 통계의 양대산맥: 기술통계


밀도추정

- 밀도 그림(Density Plot): 히스토그램을 부드러운 곡선으로 나타낸 그림. 커널밀도추정(Kernel Density Estimation)을 주로 사용. 히스토그램과 가장 큰 차이는 바로 y축 값의 단위로 밀도 그림에서는 개수가 아닌 비율을 표시
- 바이올린 도표(Violin Plot): 상자그림을 보완한 형태로, y축을 따라 밀도추정 결과를 동시에 시각화. 밀도 분포 모양을 좌우대칭으로 서로 겹쳐지도록 해놓고 보면 바이올린을 닮은 모양으로 상자그림에서는 보이지 않는 데이터의 분포를 볼 수 있다는 것이 장점

4. 통계의 양대산맥: 기술통계

밀도추정


- 밀도 그림(Density Plot): 히스토그램을 부드러운 곡선으로 나타낸 그림. 커널밀도추정(Kernel Density Estimation)을 주로 사용. 히스토그램과 가장 큰 차이는 바로 y축 값의 단위로 밀도 그림에서는 개수가 아닌 비율을 표시



4. 통계의 양대산맥: 기술통계

밀도추정

- 바이올린 도표(Violin Plot): 상자그림을 보완한 형태로, y축을 따라 밀도추정 결과를 동시에 시각화. 밀도 분포 모양을 좌우대칭으로 서로 겹쳐지도록 해놓고 보면 바이올린을 닮은 모양으로 상자그림에서는 보이지 않는 데이터의 분포를 볼 수 있다는 것이 장점



SOURCE

4. 통계의 양대산맥: 기술통계

- 위치 추정
 - 평균 (Mean)
 - 중간값 / 중앙값 (Median)
- 변이 추정
 - 표준편차와 관련 추정값들
 - 백분위수에 기초한 추정
- 데이터 분포 탐색
 - 백분위수와 상자그림
 - 도수분포표와 히스토그램
 - 밀도추정
- 이진 데이터와 범주 데이터 탐색
 - 최빈값 (Mode)
- 상관관계
 - 산점도

4. 통계의 양대산맥: 기술통계

이진 데이터와 범주 데이터 탐색


- 최빈값 (Mode): 데이터에서 가장 자주 등장하는 범주 혹은 값. 예를 들면 11기에서 가장 많은 MBTI는 ISFP이다.
- 막대도표 (Bar Chart): 각 범주의 빈도수 혹은 비율을 막대로 나타낸 그림. 범주형 자료를 보여줄 때 주로 사용. 히스토그램과 매우 유사. 다만 막대도표에서 x 축은 각 요인변수 (factored variable)의 서로 다른 범주들을 나타내는 반면, 히스토그램의 x축은 수치적으로 나타낼 수 있는 하나의 변수 값을 의미. 또한 히스토그램에서 막대들은 일반적으로 서로 붙어있고, 중간에 틈이 있다는 것은 그 부분에 해당하는 값들이 존재하지 않는다는 것을 의미. 이와 달리 막대도표에서 막대들은 서로 떨어져 있음.
- 파이그림(Pie Chart): 각 범주의 빈도수 혹은 비율을 원의 부채꼴 모양으로 나타낸 그림. 막대도표 대신 사용할 수 있으나 시작적으로 효과적이지 않다는 이유도 잘 사용하지 않기도 함.

4. 통계의 양대산맥: 기술통계

✱ 어떤 상품군이 꾸준히 판매량 상위권을 차지하는가?

가설 : Ladieswear의 비중과 Baby/Children의 카테고리 상품 비율이 많은 것으로 보아 온오프라인에서 많이 팔린 상품은 두 카테고리가 중심이 될 것이다.

H&M 인기 품목 TOP10(prod_name)



+ 판매량 높은 순위 (Top10, prod_name) [상의 / 하의]

- Jade HW Skinny Denim TRS 5,919
- Luna skinny RW 4,561
- Timeless Midrise Brief 2,948
- Despacito 2,749
- Cat Tee. 2,629
- Kanta slacks RW 2,574
- Simple as That Triangle Top 2,499
- Skinny Ankle R.W Brooklyn 2,437
- Tilly (1) 2,249
- Shake it in Balconette 2,211

인사이트

- 1, 2, 6, 8위 제품이 모두 하의임을 확인할 수 있다.
- 제품 내 비율은 상의가 압도적이지만(개수), 판매량은 하의가 더 높다. 이후 실제 매출 비교도 해봤지만 데님 팬츠의 매출이 높았음.

4. 통계의 양대산맥: 기술통계


- 위치 추정
 - 평균 (Mean)
 - 중간값 / 중앙값 (Median)
- 변이 추정
 - 표준편차와 관련 추정값들
 - 백분위수에 기초한 추정
- 데이터 분포 탐색
 - 백분위수와 상자그림
 - 도수분포표와 히스토그램
 - 밀도추정
- 이진 데이터와 범주 데이터 탐색
 - 최빈값 (Mode)
- 상관관계
 - 산점도

4. 통계의 양대산맥: 기술통계

상관관계

- 상관계수(Correlation Coefficient): 수치적 변수들 간에 어떤 관계가 있는지를 나타내기 위해 사용되는 측정량 (-1 에서 +1까지의 범위). 피어슨 상관계수라고도 함.
- 상관행렬(Correlation Matrix): 행과 열이 변수들을 의미하는 표를 말하며, 각 셀은 그 행과 열에 해당하는 변수들 간의 상관관계를 의미
- 산점도(Scatter Plot): x축과 y축이 서로 다른 두 개의 변수를 나타내는 도표.

4. 통계의 양대산맥: 추론통계



4. 통계의 양대산맥: 추론통계

추론통계 (Descriptive Statistics)

- 통계적 추론 또는 추론통계는 모집단에 대한 어떠한 미지의 양상을 알기 위해 통계학을 이용하여 추측하는 과정을 지칭. 기술통계와 구별되는 개념
- 표본으로 전체를 추정하는 것
- 목적: 전수조사는 시간 / 비용 / 노력의 한계가 있으니 일부(표본)를 뽑아 전체(모집단)를 추정
- 주의사항: 일부(표본)을 잘 뽑아야 함
- 장점: 전수조사를 하지 않아도 전체(모집단)를 추정 가능
- 단점: 표본 오류와 같은 불확실성이 항상 존재

4. 통계의 양대산맥: 추론통계

추론통계 (Descriptive Statistics)

- 통계적 추론 또는 추론통계는 모집단에 대한 어떠한 미지의 양상을 알기 위해 통계학을 이용하여 추측하는 과정을 지칭. 기술통계와 구별되는 개념
- 표본으로 전체를 추정하는 것
- 목적: 전수조사는 시간 / 비용 / 노력의 한계가 있으니 일부(표본)를 뽑아 전체(모집단)를 추정
- **주의사항: 일부(표본)을 잘 뽑아야 함**
- 장점: 전수조사를 하지 않아도 전체(모집단)를 추정 가능
- 단점: 표본 오류와 같은 불확실성이 항상 존재

4. 통계의 양대산맥: 추론통계




STATISTICS

4. 통계의 양대산맥: 추론통계

GALLUP®

HYERI KANG

4 & 5. 통계의 양대산맥



SOURCE

HYERI KANG

6. 통계 이론 1회차 정리

통계에 관한 간단한 설문조사 (중복 선택 가능)

1. 저는 통계가 싫어요.
2. 저는 통계가 어려워요.
3. 저는 통계를 몰라요.
4. 저는 통계 전공자입니다. (훗)
5. 저는 통계가 좋아요.
6. 저는 통계 성애자입니다.

6. 통계 이론 1회차 정리

통계에 관한 간단한 설문조사 (중복 선택 가능)

1. 저는 통계가 싫어요.
2. 저는 통계가 어려워요.
3. ~~저는 통계를 몰라요.~~
4. 저는 통계 전공자입니다. (훗)
5. 저는 통계가 좋아요.
6. 저는 통계 성애자입니다.

6. 통계 이론 1회차 정리

즉 우리는

1. 통계를 이미 일상생활에서 접해서 알고 있고 혹은 아예 모르지는 않고
2. 기술통계를 통해 데이터를 이해했고 (이상값, 분포, 편향 등을 확인 & 판단하고 EDA를 하기 위해)
3. 추론통계를 통해 신뢰할 수 있는 추론과 검증을 할 예정이고 (우연인지, 의미 있는 차이인지 구분하기 위해)
4. 이러한 통계를 통해 앞으로 배울 머신러닝과 모델링에 대해 더 잘 이해할 예정이고 (선형 회귀, 분류, 확률 등 통계적 개념에 기반한 모델들 이해하기 위해)
5. 이를 기반으로 분석가가 되어 다른 사람들을 설득할 줄 알아야 합니다. (명확한 수치와 통계적 근거로 이야기하여 설득력을 높이기 위해)

STATISTICS

6. 통계 이론 1회차 정리

“통계로 거짓말하기는 쉬워도,
통계없이 진실을 말하기는 어렵다.”

STATISTICS

THANK YOU

HYERI KANG