

STATISTICS

# 통계 2차시: 확률과 분포

STATISTICAL THEORY

HYERI KANG

# TABLE OF CONTENTS

- ◆ Statistics 주제가
- ◆ 통계 이론 1회차 복습
- ◆ 확률(Probability)과  
확률변수(Random Variable)

- ◆ 확률분포(Probability Distribution)
- ◆ 정규분포(Normal Distribution)와  
표준화(Z-Score)
- ◆ 통계 이론 2회차 정리

STATISTICS

# 1. STATISTICS 주제가



HYERI KANG

## 2. 통계 이론 1회차 복습

### 통계학을 배우는 이유

- 방대한 양의 데이터를 요약하기 위해서
- 보다 나은 의사결정을 위해서
- 중요한 사회적 질문에 대답하기 위해서
- 기저귀 판매부터 범인 검거에 이르기까지 일을 보다 잘할 수 있는 패턴을 알아보기 위해서
- 사기꾼을 잡고 범인을 기소하기 위해서
- 정책, 프로그램, 약, 의료 처치, 기타 혁신의 효과를 높이기 위해서
- 비윤리적인 목적을 위해 이런 강력한 도구를 이용하는 악당을 발견하기 위해서


## 2. 통계 이론 1회차 복습

- 수치형 / 양적 데이터 (Numerical 수치형 / Quantitative 양적)
  - 이산형 (Discrete): 셀 수 있는 정수값 (고객 수, 불량품 개수, 클릭 횟수)
  - 연속형 (Continuous): 측정 가능한 실수값 (키, 몸무게, 온도, 풍속)
- 범주형 / 질적 데이터 (Categorical 범주형 / Qualitative 질적)
  - 명목형 (Nominal): 순서 없는 범주 (성별, 혈액형, 지역)
  - 순서형 (Ordinal): 순서 있는 범주 (수능 등급, 만족도 등급, 선호도 순위)
  - 이진형 (Binary): 두 개의 값 (0/1 혹은 참/거짓)만을 갖는 범주형 데이터의 특수한 경우

## 2. 통계 이론 1회차 복습

어제 받았던 좋은 질문들!

1. 금액은 왜 연속형 데이터인가요?



## 2. 통계 이론 1회차 복습

### 기술통계 (Descriptive Statistics)

- 기술통계학 또는 기술통계는 측정이나 실험에서 수집한 자료 (data)의 정리, 요약, 해석, 표현 등을 통해 자료의 특성을 규명하는 통계적 방법
- 수집한 데이터를 정리 / 요약 / 해석 / 표현
- 이미 있는 데이터를 보기 좋게 요약 및 정리하는 것
- 목적: 흐름을 빠르게 이해하고, 의사결정하기 위함
- 예를 들어, 매출 데이터를 표 혹은 그래프로 요약 및 시각화

## 2. 통계 이론 1회차 복습

### 평균

- 산술평균 (Arithmetic Mean): 데이터를 모두 더한 값을 데이터 수로 나누어 구한 평균
- 절사평균 (Trimmed Mean): 값들을 크기 순으로 정렬한 후, 양끝에서 일정 개수의 값들을 삭제한 뒤 남은 값들을 가지고 구한 평균. 정해진 개수의 극단값 (Extreme Value)을 제외한 나머지 값들의 평균
- 가중평균 (Weighted Mean): 각 데이터 값에 가중치를 곱한 값들의 총합을 다시 가중치의 총합으로 나눈 평균

## 2. 통계 이론 1회차 복습

### 중앙값

- 중간값 / 중앙값 (Median): 데이터를 일렬로 정렬했을 때, 한 가운데에 위치하는 값. 만약 데이터 개수가 짝수라면 그 중간값은 실제 데이터 값이 아닌 가운데 있는 두 값의 평균. 모든 관측치를 다 사용하는 평균과는 달리, 중간값은 정렬된 데이터의 가운데에 위치한 값들만으로 결정. 데이터에 매우 민감한 평균보다는 중간값이 많은 경우, 위치 추정에 더 유리.
- 특잇값 / 극단값: 특잇값은 어떤 데이터 집합에서 다른 값들과 매우 멀리 떨어져 있는 값을 의미. 다양한 정의가 있지만 정확한 정의는 다소 주관적일 수 있음. 특잇값은 데이터 값 자체가 유효하지 않거나 잘못되었다는 뜻이 아님. 물론 서로 다른 단위의 값들이 섞여 있거나, 센서에서 잘못된 값이 읽힌다면 결과적으로 이러한 에러값들이 특잇값으로 나타나기도 함. 특잇값들이 이러한 에러값들이라면, 평균은 무너가 잘못된 위치 추정을 할 수 있는 반면, 중간값은 여전히 설득력 있는 결과를 줄 수 있음. 물론 어떤 경우든 특잇값들을 확인하고 자세히 살펴본 후 분석을 진행해야 함.

## 2. 통계 이론 1회차 복습

### 표준편차와 관련 추정값들

- 편차(Deviation): 데이터가 평균에서 얼마나 떨어져 있는지 나타낸 값. 평균보다 크면 +, 평균보다 작으면 -.
- 분산(Variance): 데이터의 흩어짐을 볼 수 없는 편차의 한계를 극복하기 위해 등장한 개념. 제곱 편차 (모두 양수)의 평균.
- 표준편차(Standard Deviation): 분산의 단위가 제곱 단위라 직관적 해석이 어렵다는 문제에서 기반한 개념. 분산의 제곱근.

$$(\text{편차}) = (\text{각 변량}) - (\text{전체 평균})$$

$$(\text{분산}) = \frac{\text{편차의 제곱}(\text{편차}^2) \text{의 합}}{\text{총 변량의 개수}}$$

$$(\text{표준편차}) = \text{분산의 제곱근}(\sqrt{(\text{분산})})$$

SOURCE

## 2. 통계 이론 1회차 복습

### 표준편차와 관련 추정값들

- 제곱: 플러스 / 마이너스 상쇄 방지(분산 정의에 필요)
- 루트: 단위 복원 & 직관 회복 (표준편차 해석에 필요)
- 표준편차는 분산의 루트로, 현실 단위로 읽히는 변동성 지표

## 2. 통계 이론 1회차 복습


### 표준편차와 관련 예시들

- 투자 리스크
  - 펀드 A: 평균 = 2.5%, 표준편차 = 9% (상대적으로 높은 리스크)
  - 펀드 B: 평균 = 2.5%, 표준편차 = 2%
- 입시 안정성
  - 반 A: 평균 = 75, 표준편차 = 3 (상대적으로 더 안정적)
  - 반 B: 평균 = 75, 표준편차 = 20
- 품질관리
  - 공장 A: 평균 = 10cm, 표준편차 = 0.1
  - 공장 B: 평균 = 10cm, 표준편차 = 1.5 (상대적으로 높은 불량률)
- 매출 분석
  - 평균 = 30만원, 중앙값 = 5만원, 표준편차 = 22만원 (소수의 VIP가 매출을 끌어올려 평균이 상승)

## 2. 통계 이론 1회차 복습

### 백분위수에 기초한 추정

- 순서통계량(Order Statistics): 최소에서 최대까지 정렬된 데이터 값에 따른 계량형. 정렬(순위) 데이터를 나타내는 통계량
- 범위(Range): 데이터의 최댓값과 최솟값의 차이
- 백분위수(Percentile): 어떤 값들의 P퍼센트가 이 값 혹은 더 작은 값을 갖고, (100-P)퍼센트가 이 값 혹은 더 큰 값을 갖도록 하는 값
- 사분위범위(Interquartile Range, IQR): 75번째 백분위수와 25번째 백분위수 사이의 차이. 변이를 측정하는 가장 대표적인 방법





SOURCE

## 2. 통계 이론 1회차 복습

### 백분위수와 상자그림

- 상자그림(Box Plot): 투키가 데이터의 분포를 시각화하기 위한 간단한 방법으로 소개한 그림. 백분위수를 이용해 데이터의 분산을 손쉽게 시각화하는 방법. 상자부분의 위쪽과 아래쪽은 각각 75%, 25% 백분위수를 의미. 중간값은 상자안에 있는 붉은 수평선으로 표시. 구레나룻처럼 위아래로 나 있는 점선이 바로 수염(Whisker)으로 데이터 전체의 범위를 나타내주는 위 아래 선들과 연결되어 있음. 수염 부분보다 더 바깥쪽에 위치한 데이터는 각자 하나의 점으로 표시.




## 2. 통계 이론 1회차 복습

### 도수분포표와 히스토그램

- 도수분포표(Frequency Table): 어떤 구간(Interval) / 빈(Bin)에 해당하는 수치 데이터 값들의 빈도를 나타내는 기록. 변수의 범위를 동일한 크기의 구간으로 나눈 다음, 각 구간마다 몇 개의 변수 값이 존재하는지 보여주기 위해 사용. 구간의 크기가 너무 크면 분포를 나타내는 중요한 특징을 놓칠 수 있고, 반대로 너무 작으면 결과가 너무 쪼개져 있어서 더 큰 그림을 볼 수가 없게 됨.
- 히스토그램(Histogram): x축은 구간들을, y축은 해당 구간별 빈도수를 나타내는 도수분포표의 그림. 도수분포표를 시각화하는 방법.
  - 그래프에 빈 구간들이 있을 수 있다.
  - 구간은 동일한 크기를 갖는다.
  - 구간의 수 (혹은 구간의 크기)는 사용자가 결정할 수 있다.
  - 빈 구간이 있지 않은 이상, 막대 사이의 공간없이 서로 붙어있다.


## 2. 통계 이론 1회차 복습



## 2. 통계 이론 1회차 복습

### 밀도추정


- 밀도 그림(Density Plot): 히스토그램을 부드러운 곡선으로 나타낸 그림. 커널밀도추정(Kernel Density Estimation)을 주로 사용. 히스토그램과 가장 큰 차이는 바로 y축 값의 단위로 밀도 그림에서는 개수가 아닌 비율을 표시



## 2. 통계 이론 1회차 복습

### 밀도추정

- 바이올린 도표(Violin Plot): 상자그림을 보완한 형태로, y축을 따라 밀도추정 결과를 동시에 시각화. 밀도 분포 모양을 좌우대칭으로 서로 겹쳐지도록 해놓고 보면 바이올린을 닮은 모양으로 상자그림에서는 보이지 않는 데이터의 분포를 볼 수 있다는 것이 장점



## 2. 통계 이론 1회차 복습

어제 받았던 좋은 질문들!

2. Density Plot은 히스토그램보다 더 시각적으로 예쁘고 모든 특성을 담고있는것 같은데 Density Plot말고 히스토그램을 사용하는 이유가 있는건지, 마찬가지로, Violin Plot도 Box Plot의 장점과 밀도까지 볼 수 있다는 장점이 있는데 왜 box plot을 쓰는건지도 궁금합니다!






Figure 1. Common Components of Box Plot and Violin Plot. Total compensation for all academic ranks.

SOURCE

## 2. 통계 이론 1회차 복습

### 어제 받았던 좋은 질문들!

2. Density Plot은 히스토그램보다 더 시각적으로 예쁘고 모든 특성을 담고있는것 같은데 Density Plot말고 히스토그램을 사용하는 이유가 있는건지, 마찬가지로, Violin Plot도 Box Plot의 장점과 밀도까지 볼 수 있다는 장점이 있는데 왜 box plot을 쓰는건지도 궁금합니다!



- 사람의 작업 기억 용량은 제한적(대략  $4 \pm 1$  chunking 단위)
- 소화 가능한 정보량을 넘기면 이해와 설득이 급격히 하락
- 내재 부하: 주제 자체가 가진 복잡도 (단계화)
- 외재 부하: 불필요한 장식/혼잡/난해한 인터랙션이 유발 (디자인 감소)
- 본질적(정교화) 부하: 학습/이해에 기여하는 처리 (핵심 메시지 강화)

## 2. 통계 이론 1회차 복습

### 이진 데이터와 범주 데이터 탐색

- 최빈값 (Mode): 데이터에서 가장 자주 등장하는 범주 혹은 값. 예를 들면 11기에서 가장 많은 MBTI는 ISFP이다.
- 막대도표 (Bar Chart): 각 범주의 빈도수 혹은 비율을 막대로 나타낸 그림. 범주형 자료를 보여줄 때 주로 사용. 히스토그램과 매우 유사. 다만 막대도표에서 x 축은 각 요인변수 (factored variable)의 서로 다른 범주들을 나타내는 반면, 히스토그램의 x축은 수치적으로 나타낼 수 있는 하나의 변수 값을 의미. 또한 히스토그램에서 막대들은 일반적으로 서로 붙어있고, 중간에 틈이 있다는 것은 그 부분에 해당하는 값들이 존재하지 않는다는 것을 의미. 이와 달리 막대도표에서 막대들은 서로 떨어져 있음.
- 파이그림(Pie Chart): 각 범주의 빈도수 혹은 비율을 원의 부채꼴 모양으로 나타낸 그림. 막대도표 대신 사용할 수 있으나 시작적으로 효과적이지 않다는 이유도 잘 사용하지 않기도 함.

## 2. 통계 이론 1회차 복습

### 상관관계

- 상관계수(Correlation Coefficient): 수치적 변수들 간에 어떤 관계가 있는지를 나타내기 위해 사용되는 측정량 (-1 에서 +1까지의 범위). 피어슨 상관계수라고도 함.
- 상관행렬(Correlation Matrix): 행과 열이 변수들을 의미하는 표를 말하며, 각 셀은 그 행과 열에 해당하는 변수들 간의 상관관계를 의미
- 산점도(Scatter Plot): x축과 y축이 서로 다른 두 개의 변수를 나타내는 도표.

## 2. 통계 이론 1회차 복습

### 추론통계 (Descriptive Statistics)

- 통계적 추론 또는 추론통계는 모집단에 대한 어떠한 미지의 양상을 알기 위해 통계학을 이용하여 추측하는 과정을 지칭. 기술통계와 구별되는 개념
- 표본으로 전체를 추정하는 것
- 목적: 전수조사는 시간 / 비용 / 노력의 한계가 있으니 일부(표본)를 뽑아 전체(모집단)를 추정
- **주의사항: 일부(표본)을 잘 뽑아야 함**
- 장점: 전수조사를 하지 않아도 전체(모집단)를 추정 가능
- 단점: 표본 오류와 같은 불확실성이 항상 존재

## 2. 통계 이론 1회차 복습




STATISTICS

## 2. 통계 이론 1회차 복습

GALLUP®

HYERI KANG

## 2. 통계 이론 1회차 복습



## 2. 통계 이론 1회차 복습

### 즉 우리는

1. 통계를 이미 일상생활에서 접해서 알고 있고 혹은 아예 모르지는 않고
2. 기술통계를 통해 데이터를 이해했고 (이상값, 분포, 편향 등을 확인 & 판단하고 EDA를 하기 위해)
3. 추론통계를 통해 신뢰할 수 있는 추론과 검증을 할 예정이고 (우연인지, 의미 있는 차이인지 구분하기 위해)
4. 이러한 통계를 통해 앞으로 배울 머신러닝과 모델링에 대해 더 잘 이해할 예정이고 (선형 회귀, 분류, 확률 등 통계적 개념에 기반한 모델들 이해하기 위해)
5. 이를 기반으로 분석가가 되어 다른 사람들을 설득할 줄 알아야 합니다. (명확한 수치와 통계적 근거로 이야기하여 설득력을 높이기 위해)

STATISTICS

## 2. 통계 이론 1회차 복습

“통계로 거짓말하기는 쉬워도,  
통계없이 진실을 말하기는 어렵다.”

# 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

확률은 불확실성의 언어

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 뉴스 속 확률의 모호함
  - 내일 비 올 확률 70%
  - 하루 중 32%의 시간을 수면에 할애
  - 대한민국 국토 면적의 62%가 산림면적
  - 10번 중 6번을 승리하는 프로야구팀
- 사실 모두 완전히 맞지도, 틀리지도 않음
- 이 모호함을 다루는 언어가 바로 **확률**

# 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 확률은 불확실성의 언어
  - 확률은 주사위 계산 문제가 아님
  - 확률은 불확실한 세상을 이해하는 언어

# 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 생활 속 확률
  - 날씨 예보: 내일 비 올 확률 65%
  - 병원 검사: 종양이 암일 확률이 95%
  - 로또 당첨: 이번 주 1등 당첨 확률 740만 분의 1

# 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 데이터 분석가와 확률
  - 버튼 색을 바꾸면 클릭률이 올라갈 확률은? (A/B 테스트)
  - 이 상품 추천이 성공할 확률은?
  - 이번달 매출이 타겟을 넘길 확률은?

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 데이터 분석가와 확률
  - 버튼 색을 바꾸면 클릭률이 올라갈 확률은? (A/B 테스트)
  - 이 상품 추천이 성공할 확률은?
  - 이번달 매출이 타겟을 넘길 확률은?
  - 확률을 모르면 데이터 분석 자체를 시작하기 어려움
    - 데이터에 기반한 전략 제안에 확률이 필수적이기 때문
    - 내 설득을 구체적인 수치화로 알려주는 것이 데이터 분석가의 업무

# 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 정리
  - 확률은 단순한 게임 규칙이나 수학 공식이 아님
  - 데이터 분석가는 확률로 불확실성 속에서 더 나은 결정을 내림

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 통계적 실험(Statistics Experiment): '비슷한 사건이 반복'될 때, '여러가지 가능한 결과'를 알 수 있지만 '정확히 무슨 결과'가 발생할 지는 모를 때, 이러한 특성을 갖는 문제가 바로 통계학의 연구 및 응용 대상이며 통계적 실험이라 지칭
  - 막걸리 공장에서 한 기계가 제품을 반복 생산. 제품은 정상품 또는 불량품 중 하나지만 무엇이 될지는 알 수 없음
  - 매월 마지막주 일요일에는 알볼로 단호박 피자를 먹으면서 1박 2일을 보는 것이 저희집 루틴. 그리고 또다른 가풍이 피자값은 항상 내기로 이루어짐. 피자가 집에 배달되는 데 걸리는 시간은 대개 30분 이내지만 정확히 알 수 없음

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 결과(Sample Point): 실제로 관측된 딱 하나의 경우
- 사건(Event): 표본 공간의 한 부분집합 / 그 결과들이 모여있는 집합 -> 지도 위의 점 하나
- 표본공간(Sample Space, S): 통계적 실험의 모든 가능한 결과의 집합 / 일어날 수 있는 모든 경우의 전체 (보통 중괄호 {}로 표현) -> 지도 전체 (모든 경우의 수)

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 표본공간(Sample Space,  $s$ ): 통계적 실험의 모든 가능한 결과의 집합 / 일어날 수 있는 모든 경우의 전체 (보통 중괄호  $\{\}$ 로 표현) -> 지도 전체 (모든 경우의 수)
  - 이산형 표본공간(Discrete Sample Space): 표본공간의 원소개수가 유한(finite)하거나, 무한하나 셀 수 있는(countably infinite) 경우
    - 막걸리 공장 ... 한 기계 ... 제품 반복 생산 ... 정상품 또는 불량품 중 하나지만 무엇이 될지는 알 수 없음
      - 사건 = 정상품 혹은 불량품 / 표본공간 = {정상품, 불량품}
  - 연속형 표본공간(Continuous Sample Space): 표본공간의 원소개수가 무한하면서 셀 수 없을(uncountably infinite)는 경우
    - 측도: 길이, 면적, 부피 등
    - 매월 마지막주 일요일 ... 알볼로 단호박 피자 ... 1박 2일 ... 피자가 집에 배달되는데 걸리는 시간은 대개 30분 이내지만 정확히 알 수 없음 ...
      - 사건 =  $\{(0, 20)\}$  / 표본공간 =  $\{(0, \infty)\}$

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 생활 비유
  - 구슬 뽑기: 사건 = 빨간색 구슬 뽑기 / 표본공간 = {빨강, 흰색}
  - 가위바위보: 사건 = 가위 / 표본공간 = {가위, 바위, 보}
  - 카페 주문: 사건 = 따뜻한 아메리카노 주문 / 표본공간 = {따아/아아} \* {Tall/Grande/Venti} \* {우유 추가/미추가} \* {샷 추가/미추가} \* {카페인/디카페인} = 32
- 사건(Event) = 실제 선택한 하나의 & 표본공간(Sample Space) = 가능한 메뉴 전체 경우의 수

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 데이터 분석 연결
  - 고객 행동 = {구매, 미구매}
  - 광고 반응 = {클릭, 미클릭}
  - 웹사이트 방문 = {방문, 이탈}
- 분석가는 모든 경우의 수(표본공간)을 정의하고 그 중 실제로 일어난 사건을 관측

# 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

확률  $P(A)$  — 불확실성에 숫자를 붙이다

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- **확률(Probability)**: 어떤 사건이 일어날 가능성을 0과 1사이의 실수로 표시하는 것 / 사건을 숫자로 표현하는 것 / 불확실한 사건이 일어날 가능성을 0 - 1 사이의 숫자로 나타냄
  - 0 = 절대 불가능
  - 1 = 절대 가능
  - 그 사이 = 가능성의 크기
  - 사건 A가 일어날 확률 =  $P(A)$

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 생활 비유
  - 구슬 뽑기
    - 구슬 5개 중 빨강 4개, 흰색 1개
    - $P(\text{빨강}) = 4/5 = 0.8$ ,  $P(\text{흰색}) = 1/5 = 0.2$
  - 날씨 예보
    - “내일 비 올 확률 70%”
    - 같은 조건에서 10번 반복 → 평균 7번 비
- 확률 = “100번 하면 몇 번쯤 일어날까?”
  -

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 실무 사례
  - 마케팅팀: 30대 여성 고객 쿠폰 클릭 확률 12%
  - 영업팀: 20대 남성 고객 클릭 확률 7%
- 이런 확률 값으로 데이터 분석가는 **타겟팅 전략**을 설계

# 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 정리
  - 확률은 사건이 일어날 **가능성의 크기**를 숫자로 표현한 것
    - 보장도 아니고 예언도 아니다

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 동전 던지기
  - “동전을 10번 던지면 앞면이 몇 번쯤 나올?”
    - 5번쯤?
    - 운 나쁘면 2번만?
    - 어떤 땐 3번, 어떤 땐 7번
  - 그런데 동전은 항상 앞뒤가 50%인데 왜 이럼?????

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 동전 던지기
  - 10번 던지기 → 표본이 너무 적어 요동이 큼
  - 100번, 1000번 던지기 → 평균이 점점 50%에 가까워짐
  - 이 원리를 **큰 수의 법칙** 혹은 **대수의 법칙**이라고 함

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 생활 비유
  - 시험 성적
    - 모의고사 한 번 점수는 들쭉날쭉, 여러 번 평균은 안정
  - 동네 날씨
    - 하루 맑음/비, 1년 평균 강수량은 일정
  - 게임 뽑기
    - 단기엔 폭망/대박, 1000번 하면 확률대로 수렴

# 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 실무 연결
  - 주식 투자
    - 하루 수익률은 널뛰지만, 장기 평균은 안정
  - 마케팅
    - 하루 클릭률은 요동치지만, 연간 평균 클릭률은 실제 성과
  - 서비스 운영
    - 하루 불만 고객 수는 오락가락, 연간 평균 불만율은 품질 수준

# 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 정리

- 확률은 단기적으로는 불확실하지만,  
장기적으로는 규칙이 드러남
  - 큰 수의 법칙 / 대수의 법칙

# 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

확률변수 — 불확실성을 값으로 다루는 도구

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 확률변수(Random Variable)?
  - 동전을 던졌더니 앞면이 나왔습니다
  - 기록 방법?
  - "앞"이라고 글자로 쓰기
  - 숫자 1로 표시하기
- 이렇게 사건을 숫자나 값으로 바꿔 표현하는 것
  - **확률변수(Random Variable)**

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 정의
- 확률변수(Random Variable): 사건을 숫자로 번역해 수학적으로 다룰 수 있게!
  - 예: 빨강 4, 흰색 1
  - $X = \{\text{빨강}, \text{흰색}\}$
  - $P(X=\text{빨강}) = 0.8, P(X=\text{흰색}) = 0.2$
- 실제로 관찰된 값 → 실현값(realization)
  - 기억: 사건을 데이터로 저장하기 위해 숫자로 바꾼다

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 확률변수(Random Variable): 불확실성을 값으로 다루는 도구 / 불확실성을 숫자로 번역 / 사건을 숫자로 번역하는 도구 / 표본공간의 각 원소에 하나의 실수값을 대응시켜 주는 함수
  - 이산형 확률변수(Discrete Random Variable): 확률변수의 가능한 값들이 유한개 또는 무한개이나 셀 수 있는 (countably infinite) 경우
    - 값이 / 딱딱 / 끊겨 / 있음
    - 예: 주사위 눈(1~6), 동전(앞=1, 뒤=0), 하루 방문자 수
    - 특징: **세어지는 값**
  - 연속형 확률변수(Continuous Random Variable): 확률변수의 가능한 값들이 유한개 또는 무한개이며 셀 수 없는 (uncountably infinite) 경우
    - 값이 ... 무한히 ... 이어짐 ...
    - 예: 키(172.4cm), 체류시간(12.7분), 결제금액(15,320원)
    - 특징: **줄자로 재는 값**

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 생활 비유
  - 동전 던지기: 앞=1, 뒤=0
  - 주사위: 1~6
  - 고객 결제 금액: 10,000원 ~ 100,000원
  - 카페 체류시간: 5분, 5.5분, 5.75분...
- 이산형 = 세는 것 / 연속형 = 재는 것

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 실무 사례
  - 이산형 확률변수
    - 클릭 여부: 클릭 = 1, 미클릭 = 0
    - 고객 이탈 여부: 이탈 = 1, 유지 = 0
    - 불량품 개수: 0개, 1개, 2개...
  - 연속형 확률변수
    - 고객 체류시간: 평균 5.2분
    - 하루 매출액: 1,888,000원
    - 고객 나이: 25.4세

### 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 확률변수를 숫자로 바꿔놓으니...
  - 주사위 눈은 다 똑같이 나올까?
  - 고객 체류시간은 대부분 짧을까, 일부만 오래 머물까?
    - 이 질문에 답하는 게 **확률분포**
- 확률변수: 불확실성을 숫자로 번역
- 확률분포: 숫자가 어떻게 퍼져 있는지 보여주는 지도

# 3. 확률(PROBABILITY)과 확률변수(RANDOM VARIABLE)

- 정리
  - 확률변수는 사건을 숫자로 번역하는 도구,
  - 확률분포는 그 숫자가 어떻게 퍼져 있는지 보여주는 지도

## 4. 확률분포(PROBABILITY DISTRIBUTION)

확률분포 — 불확실성이 퍼진 지도

## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 주사위
  - 주사위를 100번 던졌다
    - 결과: 1, 3, 5, 6, 2, 4 ... → 길게 나열하면 복잡
  - 막대그래프로 그리면?
    - "3이 많이 나왔네, 6은 적게 나왔네" 직관적으로 보임

## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 정의
- 확률분포란:
  - 확률변수가 어떤 값을 얼마나 자주 가지는지를 보여주는 지도
  - 즉, 값  $X$ 와 확률  $P(X)$ 의 매칭
- 정리
  - "불확실성이 어떻게 퍼져 있는지 보여주는 그림"


## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 확률분포(Probability Distribution): 불확실성이 퍼진 지도 / 확률 변수로 알아낸 숫자가 어떻게 퍼져있는지 보여주는 지도(그림) / 확률변수가 어떤 값을 얼마나 자주 가지는지를 보여주는 지도
  - 이산형 분포(Discrete): 값이 뚝뚝 끊겨 있음 / 막대 그래프
  - 연속형 분포(Continuous): 값이 무한히 이어짐 / 곡선(pdf), 곡선아래면적 = 확률

## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 이산형 분포(Discrete): 값이 딱딱 끊겨 있음
  - 예: 주사위 눈(1~6, 각각  $P=1/6$ ), 동전 앞뒤, 불량품 개수
  - 시각화: 막대 그래프


주사위 100회: 관측 분포 vs 이론 분포



## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 연속형 분포(Continuous): 값이 무한히 이어짐
  - 예: 키, 체류시간, 결제금액
  - 특정 값 하나의 확률 = 0 → **범위로 계산**
  - 곡선(pdf), 곡선아래면적 = 확률

연속형 분포 예시: 표준정규분포 pdf



## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 생활 비유
  - 시험 점수: 대부분 60~70점에 몰림
  - 키: 170cm 부근이 많고, 150cm·190cm는 드물 → 종 모양
  - 배달앱 주문금액: 대부분 2~3만 원, 가끔 20만 원 넘는 긴 꼬리 분포
- 숫자만 보면 안 보이던 \*\*숲의 모양\*\*이 드러남

## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 실무 사례
  - 마케팅: 고객 결제금액 대부분 5만 원 이하, 일부는 30만 원 이상
  - 품질 관리: 부품 길이 평균 10cm, 분산이 작음 → 공정 안정
  - 서비스 운영: 고객 체류시간 평균 5분, 꼬리가 길다 → 일부는 오래 머무름
- 분석가는 분포를 보고 데이터의 특징, 안정성, 이상치를 판단

## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 정리
  - 확률분포는 확률변수가 어떻게 퍼져 있는지 보여주는 지도
    - 이산형은 막대
    - 연속형은 곡선+면적
  - 분석가는 데이터를 그냥 보지 않고, **분포의 모양**을 먼저 봄

## 4. 확률분포(PROBABILITY DISTRIBUTION)

기댓값  $E(X)$  – 평균의 또 다른 얼굴

## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 정의

- 이산형 확률변수

- $E(X) = \sum [\text{값} \times \text{확률}]$

- 연속형 확률변수

- $E(X) = \int x f(x) dx$

- 정리

- 기대값 = 확률적으로 기대되는 평균값


- 오랫동안 반복했을 때 수렴하는 값

## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 생활 비유

- 주사위:  $(1+2+3+4+5+6)/6 = 3.5$
- 동전: 앞=1, 뒤=0 → 기대값=0.5
- 100번, 1000번 반복할수록 평균이 기대값에 가까워짐
- 기대값
  - 확률적으로 기대되는 평균값
  - 오랫동안 반복했을 때 수렴하는 값
  - 가장 그럴듯한 평균 수준

## 4. 확률분포(PROBABILITY DISTRIBUTION)



## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 실무 사례

- 고객 매출: 1인당 기대 매출 = 12,000원 → 1,000명 = 1,200만 원
- 광고 클릭: 기대 클릭 = 0.08 → 페이지 10,000회 = 800클릭 예상
- 보험: 사고 확률 × 보상금액 = 기대 손실액

## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 실무 비유
  - 카지노: 단기엔 손님이 이길 수도, 장기엔 항상 카지노 승리
  - 마케팅: 하루 클릭률은 요동, 연간 평균은 안정
  - 주식: 단기 변동성 크지만, 장기 수익률은 평균으로 수렴

## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 체크?
  - 1. 기대값 = 실제로 항상 나오는 값 ?
  - 2. 기대값 = 미래를 정확히 예언 ?

## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 체크?
  - 1. 기대값 = 실제로 항상 나오는 값 ? **X**
  - 2. 기대값 = 미래를 정확히 예언 ? **X**
- 기대값은 한 번의 결과가 아니라, 많은 시도(대수의 법칙/표본크기)의 평균

## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 정리
  - 기대값은 장기적으로 기대되는 평균 수준
    - 하지만 단기 불확실성은 따로 고려해야 함
      - 분산·표준편차로 보완

# 4. 확률분포(PROBABILITY DISTRIBUTION)

분산과 표준편차 — 불확실성의 크기

## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 왜 또 분산과 표준편차?
  - 평균은 데이터의 **중심**만 알려줌
    - 같은 평균이라도 집단은 전혀 다르게 보일 수 있음
  - 그래서 필요한 게 **분산과 표준편차**
    - 데이터의 **흔들림과 안정성**을 보여주는 도구

## 4. 확률분포(PROBABILITY DISTRIBUTION)

### 표준편차와 관련 추정값들

- 편차(Deviation): 데이터가 평균에서 얼마나 떨어져 있는지 나타낸 값. 평균보다 크면 +, 평균보다 작으면 -.
- 분산(Variance): 데이터의 흩어짐을 볼 수 없는 편차의 한계를 극복하기 위해 등장한 개념. 제곱 편차 (모두 양수)의 평균.
- 표준편차(Standard Deviation): 분산의 단위가 제곱 단위라 직관적 해석이 어렵다는 문제에서 기반한 개념. 분산의 제곱근.

$$(\text{편차}) = (\text{각 변량}) - (\text{전체 평균})$$

$$(\text{분산}) = \frac{\text{편차의 제곱}(\text{편차}^2) \text{의 합}}{\text{총 변량의 개수}}$$

$$(\text{표준편차}) = \text{분산의 제곱근}(\sqrt{(\text{분산})})$$

SOURCE

## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 정의

- **분산(Variance)**: 평균에서 떨어진 정도를 **제공 평균**
  - 분산 = 퍼짐의 수학적 정의
- **표준편차(Standard Deviation)**: 분산의 제곱근 → 원래 단위로
  - 표준편차 = 퍼짐을 직관적으로 해석 가능

## 4. 확률분포(PROBABILITY DISTRIBUTION)

### 표준편차와 관련 예시들

- 투자 리스크
  - 펀드 A: 평균 = 2.5%, 표준편차 = 9% (상대적으로 높은 리스크)
  - 펀드 B: 평균 = 2.5%, 표준편차 = 2%
- 입시 안정성
  - 반 A: 평균 = 75, 표준편차 = 3 (상대적으로 더 안정적)
  - 반 B: 평균 = 75, 표준편차 = 20
- 품질관리
  - 공장 A: 평균 = 10cm, 표준편차 = 0.1
  - 공장 B: 평균 = 10cm, 표준편차 = 1.5 (상대적으로 높은 불량률)
- 매출 분석
  - 평균 = 30만원, 중앙값 = 5만원, 표준편차 = 22만원 (소수의 VIP가 매출을 끌어올려 평균이 상승)

## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 직관적 비유
- 평균 = 균형점
- 표준편차 = 파도의 거칠기
  - 파도가 잔잔하면 표준편차 ↓
  - 파도가 거칠면 표준편차 ↑



## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 정리

- 평균만 보면 같은 것처럼 보여도 **데이터의 퍼짐**은 전혀 다를 수 있음
- 그래서 평균만 보면 **착시** 가능
- 분산과 표준편차를 봐야 **흔들림과 위험**을 알 수 있음
- 분산과 표준편차가 클수록 데이터는 **불안정**

# 4. 확률분포(PROBABILITY DISTRIBUTION)

이론적 확률분포 & 파라미터

## 4. 확률분포(PROBABILITY DISTRIBUTION)

- 이론적 확률분포 & 파라미터
  - 사람마다 지문이 다르다
  - 데이터도 마찬가지로
  - **확률분포라는 지문**을 보면 집단의 특징이 드러남
- 숫자 더미만 보면 복잡하지만, 분포와 파라미터를 보면 성격이 보임

# 5. 정규분포(NORMAL DISTRIBUTION)와 표준화(Z-SCORE)

정규분포 — 세상에서 제일 자주 만나는 종(鐘)

## 5. 정규분포(NORMAL DISTRIBUTION)와 표준화(Z-SCORE)

- 숫자엔 모양이 있다
  - "확률은 불확실성의 언어"
  - 데이터를 100개·1000개 쌓아놓으면 어떤 모습?
  - 단순한 숫자 더미가 아니라 얼굴(모양)이 드러남
  - 예시: 반 학생 키 → 숫자로는 복잡
    - 그래프로 그리면 종 모양 곡선 (**정규분포**)이 나타남

## 5. 정규분포(NORMAL DISTRIBUTION)와 표준화(Z-SCORE)

68-95-99 법칙 — 범위를 보면 분포가 보인다

# 5. 정규분포(NORMAL DISTRIBUTION)와 표준화(Z-SCORE)

표준화(z) — 다른 단위도 한 줄로 공정 비교

# 5. 정규분포(NORMAL DISTRIBUTION)와 표준화(Z-SCORE)

정규분포를 '그림'으로 읽는 법

# 5. 정규분포(NORMAL DISTRIBUTION)와 표준화(Z-SCORE)

현실 적용 — 언제 정규, 언제 비정규?

STATISTICS

**THANK YOU**

HYERI KANG