

STATISTICS

# 통계 5차시: 상관관계

STATISTICAL THEORY

HYERI KANG

STATISTICS

# TABLE OF CONTENTS

◆ Statistics 주제가

◆ 상관관계 (Correlation)

◆ 상관관계와 인과관계 (Causality)

◆ A/B Test

STATISTICS

# 1. STATISTICS 주제가



HYERI KANG

## 2. 상관관계 (CORRELATION)

- 질문

- 공부시간 ↑  $\leftrightarrow$  점수 ↑ ?
- 광고비 ↑  $\leftrightarrow$  매출 ↑ ?
- 대부업 이용 ↑  $\leftrightarrow$  파산 ↑ ?



## 2. 상관관계 (CORRELATION)

- 즉,
  - 느낌이 아니라 데이터를 확인해야 함
    - 산점도로 관계를 눈으로 보기
    - 상관계수( $r$ )로 숫자로 요약하기

## 2. 상관관계 (CORRELATION)

### 2-1) 두 수치형 변수 사이의 관계를 밝히다

## 2. 상관관계 (CORRELATION)

- 두 개의 수치형 변수

- 현실 데이터는 변수가 쌍으로 존재하는 경우가 많음
- 단일 변수 평균/분산만 보지 말고, 관계를 함께 살펴야 함
- 예시
  - 학생: 공부시간  $\leftrightarrow$  시험 점수
  - 기업: 광고비  $\leftrightarrow$  매출
  - 사회: 대부업 이용자 수  $\leftrightarrow$  파산 건수

## 2. 상관관계 (CORRELATION)

- 관계 보기의 의미

- 변수 하나씩만 보면 평균 정도만 알 수 있음
- 두 변수를 함께 봐야 **관계**를 확인할 수 있음
- 질문
  - 공부시간이 늘수록 점수도 늘까?

## 2. 상관관계 (CORRELATION)

- 실무

- 데이터분석가가 자주 묻는 질문
  - 광고비와 매출은 같이 움직이는가?
  - 고객 활동량이 많을수록 이탈률은 줄어드는가?
- → 분석 초점은 항상
- “변수 하나씩 보기 → 변수 간 관계 보기”



## 2. 상관관계 (CORRELATION)

- 범주형 변수와의 차이

- 상관계수는 수치형 변수끼리만 계산 가능
- 범주형(성별, 지역, 학과 등)에는 적용 불가
- 예시
  - 성별  $\leftrightarrow$  점수  $\rightarrow$  상관 X
  - 해결: 교차표, 카이제곱 검정, 평균 차이 검정 등

## 2. 상관관계 (CORRELATION)

| 학생 | 성별 | 공부시간 | 점수 |
|----|----|------|----|
| A  | 남  | 1    | 50 |
| B  | 여  | 3    | 65 |
| C  | 남  | 5    | 80 |

- 성별(범주형) → 상관 계산 불가
- 공부시간과 점수(수치형 변수) → 상관분석 가능

## 2. 상관관계 (CORRELATION)

- 체크

- 다음 중 상관계수를 계산할 수 있는 변수 조합은?
  - 성별 <-> 점수
  - 공부시간 <-> 점수
  - 지역 <-> 매출



## 2. 상관관계 (CORRELATION)


- 체크

- 다음 중 상관계수를 계산할 수 있는 변수 조합은?
  - 성별 <-> 점수
  - 공부시간 <-> 점수 (수치형 변수끼리)
  - 지역 <-> 매출

## 2. 상관관계 (CORRELATION)

### 2-2) 산점도

## 2. 상관관계 (CORRELATION)



## 2. 상관관계 (CORRELATION)

- 산점도의 의미

- 두 변수를 동시에 그릴 때 가장 기본 도구
  - 방향
  - 강도
  - 모양
- 각 데이터 한 점이  $(x, y)$  좌표 위에 찍힘
  - 우상향  $\rightarrow$  양의 상관
  - 우하향  $\rightarrow$  음의 상관
  - 제멋대로 흩어짐  $\rightarrow$  약한 상관

## 2. 상관관계 (CORRELATION)

- 왜 산점도가 중요할까?

- 상관 분석의 출발점
  - 상관계수(r)
- 상관계수(r)만 보고 판단하면 위험
  - 비선형 관계
  - 이상치 하나가 만든 가짜 상관
  - 서로 다른 두 패턴의 혼합
- 상관계수 범위
  - $-1 \leq r \leq +1$
- 숫자는 왜곡될 수 있지만, 그림은 직관적으로 관계를 보여줌



## 2. 상관관계 (CORRELATION)

- 실무 연결

- 예: 광고비  $\leftrightarrow$  매출
- 상관관계수  $r=0.6 \rightarrow$  하지만 산점도를 보니 이상치 때문에 과장된 값일 수도 있음
- 데이터분석가는 항상 숫자 + 그림을 함께 제시해야 한다

## 2. 상관관계 (CORRELATION)

- 체크

- 질문: “상관계수  $r=0.8$ 이라고 보고만 받았습니다.
- 여러분이라면 어떤 차트를 꼭 추가로 확인하고 싶나요?”

## 2. 상관관계 (CORRELATION)

- 체크

- 질문: “상관계수  $r=0.8$ 이라고 보고만 받았습니다.
- 여러분이라면 어떤 차트를 꼭 추가로 확인하고 싶나요?”
  - → 산점도



## 2. 상관관계 (CORRELATION)

### 2-3) 상관(相關)

## 2. 상관관계 (CORRELATION)

### • 상관계수 정의

- 산점도는 관계를 눈으로 확인하므로, 보는 사람마다 해석이 다를 수 있음
- 그래서 산점도의 패턴을 숫자 하나로 요약
- 이 숫자가 상관계수  $r$  ( $-1 \sim +1$ )
  - → 즉 두 수치형 변수가 얼마나 **직선적(선형)**으로 같이 움직이지는 숫자로 요약한 값

# PART 1. 모집단과 표본

- 왜 필요한가?


- 데이터가 수백·수천 개면 산점도만으로는 해석이 어려움
  - 또한 차트는 보는 사람마다 다르게 해석할 수 있음
- 상관계수( $r$ )는 **딱 두 가지**를 알려줌
  - **방향** (+ / -)
  - **강도** (약 / 중 / 강)

## 2. 상관관계 (CORRELATION)

- 예시


- 공부시간  $\leftrightarrow$  점수  $\Rightarrow 0.94 \Rightarrow$  양의 상관 (같이 증가)
- 나이  $\leftrightarrow$  게임시간:  $\Rightarrow -0.6 \Rightarrow$  음의 상관 (한쪽 증가, 다른 쪽 감소)
- 주민등록번호  $\leftrightarrow$  점수:  $\Rightarrow 0 \Rightarrow$  관계 없음 ( $r \approx 0$ )
  - 관계 없음  $\rightarrow$  관계 없다는게 아님
    - 선형 관계가 없다는 말임

## 2. 상관관계 (CORRELATION)






## 2. 상관관계 (CORRELATION)



## 2. 상관관계 (CORRELATION)



## 2. 상관관계 (CORRELATION)

### 2-4) 회귀(回歸)



## 2. 상관관계 (CORRELATION)

- 왜 회귀가 필요할까?


- 상관은 두 변수가 "같이 움직인다"는 사실만 요약
- 하지만 이런 질문에는 답하지 못함:
  - 광고비를 100만 원 늘리면, 매출은 얼마나 늘까?
  - 공부시간이 1시간 늘면, 점수는 몇 점 올라갈까?
    - → 영향력의 크기를 알고 싶을 때 필요한 도구가 바로 회귀(Regression)

## 2. 상관관계 (CORRELATION)


- 상관 vs 회귀

- 상관: 두 변수를 동등하게 다룸 ( $A \leftrightarrow B$ , 순서 없음)
- 회귀: 한 변수를 설명변수( $x$ ), 다른 변수를 반응변수( $y$ )로 두고 방향성을 가정
  - 회귀는  $x$ 가 변할 때  $y$ 가 어떻게 변하는가를 봄

## 2. 상관관계 (CORRELATION)



## 2. 상관관계 (CORRELATION)



## 2. 상관관계 (CORRELATION)

- 예시

- 상관: "공부시간과 점수가 함께 늘어난다" (같이 움직임)
- 회귀: "공부시간이 1시간 늘 때 점수가 평균 5점 오른다" (영향력 수치화)



## 2. 상관관계 (CORRELATION)

- 실무

- 마케팅 광고비와 매출은 관련 있음 (그래서 어찌라구?)
- "광고비를 100만 원 늘리면 매출이 평균 얼마 늘어난다"라는 구체적 수치를 원함
  - → 이때 회귀분석이 강력한 도구가 됨

## 2. 상관관계 (CORRELATION)

- 체크

- 다음 중 회귀분석이 상관분석과 다른 점은 무엇일까요?
  - 1. 관계를 숫자로 표현한다
  - 2. 설명변수와 반응변수를 구분한다

## 2. 상관관계 (CORRELATION)

- 체크

- 다음 중 회귀분석이 상관분석과 다른 점은 무엇일까요?
  - 1. 관계를 숫자로 표현한다
  - 2. 설명변수와 반응변수를 구분한다



## 2. 상관관계 (CORRELATION)

### 2-5) 피어슨 상관계수

## 2. 상관관계 (CORRELATION)

- 정의

- 가장 널리 쓰이는 상관계수 = 피어슨 상관계수 (Pearson's - r)
  - 값의 범위:  $-1 \sim +1$
  - 두 변수의 선형 관계 강도를 나타냄
  - $r = +1 \rightarrow$  완벽한 양의 상관
  - $r = -1 \rightarrow$  완벽한 음의 상관
  - $r = 0 \rightarrow$  선형 관계 없음

## 2. 상관관계 (CORRELATION)

- 이게 뭐냐면

- $\text{Cov}(X, Y) / (\sigma_X, \sigma_Y)$
- 공분산: 두 변수가 얼마나 같이 움직이는가
- $\sigma_X, \sigma_Y$ : 각 변수의 표준편차
- 공분산은 단위에 따라 크기가 달라짐
  - → 표준편차로 나누어 단위를 없애고  $-1 \sim +1$ 로 정규화

## 2. 상관관계 (CORRELATION)

- 예시

- 공부시간  $\leftrightarrow$  점수  $\rightarrow r = +0.8$  (강한 양의 상관)
- 나이  $\leftrightarrow$  게임시간  $\rightarrow r = -0.6$  (음의 상관)
- 주민등록번호  $\leftrightarrow$  점수  $\rightarrow r \approx 0$  (관계 없음)


## 2. 상관관계 (CORRELATION)

- 해석 기준


- $|r| < 0.3 \rightarrow$  약한 상관
- $0.3 \leq |r| < 0.7 \rightarrow$  중간 정도 상관
- $|r| \geq 0.7 \rightarrow$  강한 상관
  - 맥락에 따라 해석이 달라짐




## 2. 상관관계 (CORRELATION)



## 2. 상관관계 (CORRELATION)



## 2. 상관관계 (CORRELATION)





## 2. 상관관계 (CORRELATION)

- 실무

- 보고서 예시:

- “광고비와 매출은  $r=0.65$ 로 중간 정도의 양의 상관을 보였다.”
    - 반드시 첨부해야 하는 문구:
      - “이는 인과관계를 의미하지 않는다.”
    - → 상관은 같이 움직임만 보여줄 뿐, 원인·결과 증명 아님

## 2. 상관관계 (CORRELATION)

- 체크

- $r=0$ 이면 두 변수는 관계가 전혀 없다

## 2. 상관관계 (CORRELATION)

- 체크

- $r=0$ 이면 두 변수는 관계가 전혀 없다
  - → 아님 (선형 관계 없음일 뿐, 곡선 관계는 가능):
  - 피어슨 상관계수는 (공분산)을 각 변수의 (표준편차)로 나눈 값

## 2. 상관관계 (CORRELATION)

### 2-6) 상관 해석 기준

## 2. 상관관계 (CORRELATION)

- 해석 기준

- $|r| < 0.3 \rightarrow$  약한 상관
- $0.3 \leq |r| < 0.7 \rightarrow$  중간 정도 상관
- $|r| \geq 0.7 \rightarrow$  강한 상관



## 2. 상관관계 (CORRELATION)

- 주의사항

- $r$ 이 크다고 무조건 "좋다/의미 있다" 아님
- 연구 맥락에 따라 해석 달라짐
- 예시
  - 사회과학:  $r=0.3$ 도 큰 의미
  - 물리학:  $r=0.95$  이상이어야 신뢰

## 2. 상관관계 (CORRELATION)

- 보고서 작성 시

- 단순히 " $r=0.45 \rightarrow$  중간 정도"라고 끝내지 말 것
- 올바른 예시:
  - " $r=0.45$ 로 중간 정도의 상관이 관찰되었으며,
  - 이는 고객 행동 데이터를 다룰 때 의미 있는 수준."

## 2. 상관관계 (CORRELATION)

### 2-7) 이상치의 영향



## 2. 상관관계 (CORRELATION)

- 왜 이상치가 문제일까?


- 상관계수  $r$ 은 **평균과 분산** 기반
- 평균과 분산은 이상치 하나만 들어와도 크게 흔들림
- 따라서 상관계수도 **이상치에 매우 민감**

## 2. 상관관계 (CORRELATION)


- 예시

- 대부분 학생: 공부시간  $\uparrow \rightarrow$  점수  $\uparrow \rightarrow r \approx 0.85$
- 한 학생이 백지 제출(점수=0)  $\rightarrow r \approx 0.55$ 로 하락
  - $\rightarrow$  상관계수가 급격히 낮아짐

## 2. 상관관계 (CORRELATION)



## 2. 상관관계 (CORRELATION)



## 2. 상관관계 (CORRELATION)

- 실무

- 마케팅 데이터에서도 동일 현상 발생
- 광고비 $\leftrightarrow$ 매출 관계에서, 특정 대형 고객의 매출=0  $\rightarrow$  r 값 왜곡
  - $\rightarrow$  항상 산점도 + r 값 함께 제시
  - $\rightarrow$  숫자만 보고 보고서 작성 금지



## 2. 상관관계 (CORRELATION)

- 체크

- 질문: 상관계수가 이상치 하나 때문에 크게 바뀌었다면,
- 우리가 가장 먼저 확인해야 할 것은?

## 2. 상관관계 (CORRELATION)

- 체크

- 질문: 상관계수가 이상치 하나 때문에 크게 바뀌었다면,
- 우리가 가장 먼저 확인해야 할 것은? **산점도**

## 2. 상관관계 (CORRELATION)

### 2-8) 비모수 상관계수 (Spearman)



## 2. 상관관계 (CORRELATION)

- 개념

- 피어슨: **실제 값** 기반 → 선형 관계 측정
- 스피어만: **순위(rank)** 기반 → 값이 아니라 순서만 반영
- 장점
  - 이상치에 덜 민감
  - 곡선(비선형) 관계도 잡아낼 수 있음

## 2. 상관관계 (CORRELATION)

- 예시

- 학생 10명: 공부시간  $\uparrow \rightarrow$  점수  $\uparrow$
- 순서(랭크)만 유지되면 Spearman  $r$ 은 높음
- 특정 학생이 0점을 받아도,
- 순위 전체가 크게 바뀌지 않으면 값은 안정적
  - $\rightarrow$  순위만 맞으면 값이 튀어도 괜찮음

## 2. 상관관계 (CORRELATION)

- 실무 연결

- 금융 데이터: 주가처럼 이상치가 잦은 경우 → 스피어만
- 설문 데이터: 1~5점 서열척도 → 스피어만

## 2. 상관관계 (CORRELATION)

- 체크
  - OX: 스피어만 상관계수는 실제 값 그대로를 이용

## 2. 상관관계 (CORRELATION)

- 체크
  - OX: 스피어만 상관계수는 실제 값 그대로를 이용
    - X. 실제 값이 아니라 순서 반영



## 2. 상관관계 (CORRELATION)

- 체크

- 고객 만족도를 1~5점 척도로 조사했을 때,
- 피어슨 vs 스피어만 중 어느 것이 더 적절함?

## 2. 상관관계 (CORRELATION)

- 체크

- 고객 만족도를 1~5점 척도로 조사했을 때,
- 피어슨 vs **스피어만** 중 어느 것이 더 적절함?
  - 순서 반영 **스피어만**

## 2. 상관관계 (CORRELATION)

### 2-9) 상관계수와 가설검정



## 2. 상관관계 (CORRELATION)

- 왜 검정이 필요할까?
  - $r$  값을 계산했다고 해서
    - → 그게 진짜 관계인지, 우연인지 알 수 없음
  - 따라서 **통계적 검정**이 필요

## 2. 상관관계 (CORRELATION)

- 가설 설정

- 귀무가설( $H_0$ ): 모집단에서 상관이 없다 ( $\rho = 0$ )
- 대립가설( $H_1$ ): 모집단에서 상관이 있다 ( $\rho \neq 0$ )

## 2. 상관관계 (CORRELATION)

- 판정 기준

- $p < 0.05 \rightarrow$  우연이라고 보기 어렵다  $\rightarrow$  유의한 상관
- $p \geq 0.05 \rightarrow$  우연일 수도 있다  $\rightarrow$  단정할 수 없음

## 2. 상관관계 (CORRELATION)

- 신뢰구간 연결

- 예:  $r$ 의 95% 신뢰구간이  $(-0.1 \sim 0.6)$ 
  - 0 포함  $\rightarrow$  상관 없을 수도 있음 ( $p \geq 0.05$ )
  - 0 미포함 (예:  $0.2 \sim 0.7$ )  $\rightarrow$  상관 유의 ( $p < 0.05$ )
- 여기서 0은 무엇?

## 2. 상관관계 (CORRELATION)

- 상관계수 신뢰구간 예시

- Case A: 신뢰구간  $(-0.1 \sim 0.6)$ , 0 포함  $\rightarrow$  상관 유의하지 않음
- Case B: 신뢰구간  $(0.2 \sim 0.7)$ , 0 미포함  $\rightarrow$  상관 유의



## 2. 상관관계 (CORRELATION)

- 보고서
  - 잘못된 문장
    - 광고비와 매출의 상관계수는  $r=0.35$
  - 올바른 문장
    - 광고비와 매출의 상관계수는  $r=0.35$ ,
    - $p<0.05$ 로 통계적으로 유의
    - 이는 두 변수 간에 우연 이상의 선형 관계가 있음을 시사

## 2. 상관관계 (CORRELATION)

### 2-10) 비선형 상관

## 2. 상관관계 (CORRELATION)


- $r=0$  = 관계 없음?
  - 많은 사람들이  $r=0$ 이면 "관계가 없다"고 해석
  - 그러나 피어슨 상관계수는 직선(선형) 관계만 측정
  - 곡선 관계는 잡아내지 못함




## 2. 상관관계 (CORRELATION)

- 예시: 공부시간  $\leftrightarrow$  집중력
  - 0시간  $\rightarrow$  집중력 낮음
  - 5시간  $\rightarrow$  집중력 최고점
  - 12시간  $\rightarrow$  과로로 집중력 하락  $\rightarrow \pi\pi\pi\pi\pi$ 
    - $\rightarrow$  곡선( $\cap$  모양) 관계에서는  $r \approx 0$ 일 수 있음
    - $\rightarrow$  실제로는 강한 **비선형 관계**

## 2. 상관관계 (CORRELATION)



## 2. 상관관계 (CORRELATION)



## 2. 상관관계 (CORRELATION)

- 실무 연결

- 광고비 <-> 매출 관계
- 일정 수준까지 광고비 ↑ → 매출 ↑
- 일정 수준 넘어가면 광고 효과 감소, 심지어 손해
  - → 선형 상관만 보면 "관계 없음"처럼 나오지만,
  - 실제로는 **비선형 관계**

## 2. 상관관계 (CORRELATION)

- 체크리스트

- 1. 산점도 먼저
  - 상관 분석의 출발점은 항상 산점도
  - 숫자( $r$ )만 보면 위험
- 2. 피어슨 상관계수
  - 값 범위:  $-1 \sim +1$
  - 선형 관계의 강도와 방향



## 2. 상관관계 (CORRELATION)

- 3. 스피어만 상관계수
  - 순위 기반 계산
  - 이상치·비선형 관계에서도 안정적
- 4. 해석 기준 (분석에 따라 맥락 필요)
  - $|r| < 0.3 \rightarrow$  약한 상관
  - $0.3 \leq |r| < 0.7 \rightarrow$  중간 정도 상관
  - $|r| \geq 0.7 \rightarrow$  강한 상관
  - 연구 분야·데이터 특성에 따라 해석 달라짐

## 2. 상관관계 (CORRELATION)

- 5. 데이터 품질의 영향
  - 이상치·결측치에 민감
  - 표본이 작으면  $r$  값이 불안정
- 6. 검정과 신뢰구간
  - $p$ 값, 신뢰구간으로 우연 여부 확인

## 2. 상관관계 (CORRELATION)

- 7. 변수 유형
  - 양적 변수에만 사용 가능
  - 범주형은  $\chi^2$ , t-test 등 활용
- 8. 상관 vs 회귀 차이
  - 상관: 대칭적 ( $A \leftrightarrow B$ )
  - 회귀: 비대칭적 ( $x \rightarrow y$ )



## 2. 상관관계 (CORRELATION)

- 9. 분석의 위치
  - 상관은 **EDA 도구**
  - 예측·인과 추론 단독 근거로 부적절
- 10. 보고서 작성 습관
  - $r$  값만 쓰지 말 것
  - 산점도 + 해석 문장 포함
  - 예:
    - “광고비와 매출은  $r=0.65$ 로 중간 정도 양의 상관
    - 단, 인과는 의미하지 않음.”

# 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

## 3-1) 인과와 상관 : 잘못된 해석을 방지하기 위한 사고방식

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 인과관계 밝히기

- 데이터에서 "관계가 있다"는 건 쉽게 알 수 있음
  - 광고비와 매출이 같이 움직인다
  - 공부시간이 늘면 점수도 늘어난다
- 하지만 "원인이다"라고 말하는 건 전혀 다른 문제
- 인과관계 밝히기란?
  - 한 변수가 다른 변수에 실제 영향을 주었는지 입증하는 것
  - 즉, 단순 상관을 넘어 "A 때문에 B가 일어났다"를 보여주는 것

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 일상 사례

- 아이스크림 판매량 ↑  $\leftrightarrow$  익사 사고 ↑
  - $\rightarrow$  원인은 아이스크림이 아니라 여름 더위
- 치킨집 많음  $\leftrightarrow$  소화제 판매 ↑
  - $\rightarrow$  원인은 치킨이 아니라 "야식 문화"

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 실무 연결

- 마케팅팀:
  - 광고비  $\uparrow \rightarrow$  매출  $\uparrow$ 
    - $\rightarrow$  광고 때문일까, 명절 시즌 때문일까?
- 금융권:
  - 대부업 대출  $\uparrow \rightarrow$  SNS  $\uparrow$



### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 그래서 우리는
  - 상관이 있다고 해서 원인이라 단정하지 않는다
  - 항상 교란변수 존재 가능성을 의심해야 한다

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 체크

- 질문: 인과관계를 밝히려면 단순 상관 이상이 필요한 이유는?

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 체크

- 질문: 인과관계를 밝히려면 단순 상관 이상이 필요한 이유는?
  - 관계의 강도를 더 크게 보이기 위해
  - 제3의 요인(교란변수) 때문일 수 있기 때문에



### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 상관 vs 인과

- 상관: 단순히 "같이 움직인다"
  - 예: 광고비 ↑ → 매출 ↑ (같이 움직임)
- 인과: A 때문에 B가 생겼다 (원인-결과)
  - 예: 광고비 ↑ → 매출 ↑ (원인과 결과 연결)

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 중요한 포인트

- 모든 인과관계에는 상관성이 있음
- 하지만 모든 상관관계가 인과는 아님
  - 우연, 교란변수 때문일 수 있음

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 사례 비교

- 상관: 아이스크림 판매량  $\leftrightarrow$  익사 건수 (여름 더위 때문)
- 상관: 치킨집 수  $\leftrightarrow$  소화제 판매량 (야식 문화 때문)

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 실무 연결

- 광고비와 매출 사이의 상관 발견
- 곧바로 "광고비가 원인"이라 단정하면 위험
- 프로모션, 계절 요인, 경제 상황 같은 교란변수 가능

# 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 항상 구분
  - 지금 보고 있는 게 상관인지?
  - 인과라면 어떤 추가 증거가 필요한지?



### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 체크

- 질문: 인과가 성립하기 위해 상관만으로는 부족한 이유는 무엇일까요?

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 체크

- 질문: 인과가 성립하기 위해 상관만으로는 부족한 이유는 무엇일까요?
  - 상관계수가 낮아서
  - 제3의 요인이나 시간적 선후 관계가 고려되지 않았기 때문에

# 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

## 3-2) 다양한 사례



### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 사례 1: 치약 사용  $\leftrightarrow$  충치율
  - 데이터: 치약 사용량  $\uparrow \rightarrow$  충치율도  $\uparrow$
  - 착각: 치약이 충치를 만든다?
  - 교란변수: 이미 충치가 있는 사람들이 양치질을 더 자주 함

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 사례 2: 커피 섭취 <-> 수명

- 연구: 커피를 많이 마시는 사람들이 오래 산다
- 착각: 커피가 장수 비결?
- 교란변수: 소득 수준, 건강검진 등 생활습관 요인

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 교혼

- 단순한 상관을 인과로 착각하면 위험
- 진짜 원인은 교란변수(confounding variable)일 수 있음
- 분석가는 항상
  - 혹시 숨은 변수가 있는 건 아닐까?
  - 라고 의심해야 함

# 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 체크

- 질문: 교란변수의 정의는 무엇일까요?

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 체크

- 질문: 교란변수의 정의는 무엇일까요?
  - 두 변수 모두에 영향을 주어 잘못된 상관을 만들어내는 숨은 요인
  - 데이터를 왜곡시키는 극단값(outlier)



## 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

### 3-3) 무작위 통제 실험 (Randomized Controlled Trial, RCT)

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 인과를 밝히는 조건

- 두 집단을 비교할 때 필요한 조건:
- 원인만 다르고, 나머지는 똑같아야 함
- 예: 광고비가 매출에 영향을 주는지 확인
  - 광고를 본 그룹(실험군)
  - 광고를 보지 않은 그룹(대조군)
    - → 두 집단의 차이는 광고 여부만 있어야 함
    - → 그래야 매출 차이를 광고 때문이라고 말할 수 있음

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 비유

- 위고비 효과를 검증하려면
  - 한 그룹은 위고비를 맞고
  - 다른 그룹은 안 맞는다
- 하지만 한 그룹이 운동선수, 다른 그룹이 집돌이라면?
  - → 약 효과가 아니라 생활습관 차이 때문일 수 있음
- 따라서 두 집단을 비슷하게 맞추는 과정이 필수



# 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 실무/정책 사례

- 의학: 신약 임상시험 → 약 투여 vs 위약 그룹 비교
- 비즈니스: A/B 테스트 → 버튼 색 변경 그룹 vs 기존 그룹
- 정책: 복지 프로그램 도입 지역 vs 미도입 지역 비교

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 체크

- 질문: 인과를 밝히려면 두 집단이 어떻게 달라야 할까요?
  - 1. 모든 조건이 다 달라야 함
  - 2. 원인만 달라야 하고, 나머지는 같아야 함

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 체크

- 질문: 인과를 밝히려면 두 집단이 어떻게 달라야 할까요?
  - 1. 모든 조건이 다 달라야 함
  - 2. 원인만 달라야 하고, 나머지는 같아야 함

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 요약

- 실험군: 신약 투여
- 대조군: 위약(가짜 약)
- 무작위 배정: 두 집단을 동등하게 만들기 위해 필수
  - 누가 어느 그룹에 속할지는 무작위 배정으로 결정
  - 차이는 오직 "원인(약 투여 여부)" 하나뿐
  - 결과 차이를 약 때문이라 말할 수 있음
  - 인과 확인의 황금 표준

# 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 실무/정책 사례

- 의학: 신약 임상시험 (수천 명 무작위 배정)
- 비즈니스: 온라인 서비스 A/B 테스트
- 정책: 일부 학교에만 새 교육 프로그램 적용 후 성취도 비교



### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 심화 포인트

- 교란변수 제거 효과: 무작위 배정으로 "원래 건강해서 나은 것" 같은 요인 최소화
- 현실적 한계
  - 비용이 크다
  - 윤리적 문제 (예: 약을 주지 않는 집단이 피해 볼 수 있음)

# 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

## 체크

1.OX: RCT는 두 집단의 모든 조건을 완전히 같게 만든다

# 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

## 3-4) 인과효과를 추정하는 또 다른 방법



### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 왜 필요할까?

- 현실에서는 RCT를 하기 어려운 경우가 많음
  - 예: 교육 정책 → 일부 학생만 다른 교재 사용? 윤리적 문제 발생
- 대안: 통계적 인과 추론
  - 데이터를 가지고 최대한 실험을 흉내 내는 방식
  - 완벽하지 않지만, 인과효과를 추정할 수 있음

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 주요 방법

- 매칭 (Matching)
  - 비슷한 특성을 가진 집단끼리 짝지어 비교
  - 예: 연령·성별·소득이 같은 사람 → 적용군 vs 미적용군
- 자연실험 (Natural Experiment)
  - 세상에서 우연히 발생한 사건을 실험처럼 활용
  - 예: 특정 지역만 우연히 규제를 먼저 적용
- 차분의 차분 (Difference-in-Differences, DiD)
  - 정책 도입 전후 변화를 정책 지역 vs 비정책 지역으로 비교
  - 예: 최저임금 인상 지역 vs 비인상 지역의 고용률 변화

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 실무/정책 사례

- 비즈니스: A/B 테스트 불가능할 때, 과거 데이터에서 유사 고객을 매칭해 비교
- 정책: 특정 지역에만 복지 프로그램 도입 → 도입 vs 비도입 지역 비교

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 보고서 작성

- 잘못된 문장
  - "이 정책이 고용률을 증가시킴" (인과 단정)
- 올바른 문장
  - "자연실험 기법을 적용한 결과, 정책 도입 지역의 고용률은 비도입 지역보다 평균 3%p 높았음"
  - 이는 정책 효과일 가능성을 시사하지만, 완전한 인과 증명은 아님"

### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 광고 효과 검증 (A/B 테스트)

- 마케팅팀 질문: "광고비가 매출을 끌어올릴까?"
  - 고객을 무작위로 두 집단으로 나눔
    - 광고 노출군 vs 비노출군
  - 두 그룹 매출 차이 → 광고 효과 확인 가능
- 실무 보고서 문장 예시
  - "A/B 테스트 결과,
  - 광고 노출군의 매출은 비노출군보다 평균 12% 높았음( $p < 0.05$ )
  - 이는 광고 효과일 가능성을 시사함"



### 3. 상관관계 (CORRELATION)와 인과관계 (CAUSALITY)

- 신약 임상시험

- 인과 확인의 대표적 방법 = 임상시험
  - 한 그룹: 신약 투여
  - 다른 그룹: 위약(가짜 약) 투여
  - 무작위 배정으로 두 그룹 조건을 동일하게
- 실무 보고서 문장 예시
  - "임상시험에서 신약 투여군의 증상 개선률은 대조군보다 유의하게 높았음"
  - 무작위 배정으로 다른 요인을 배제했으므로, 이는 약효로 해석할 수 있음"

## 4. A/B TEST

- A/B 테스트란?

- 가설을 검증하기 위한 실험
  - 기존 기능보다 새로운 기능이 더 나은지 검증하기 위한 실험
- IT 업계에서 널리 사용
- 인과관계 추론의 핵심 도구

## 4. A/B TEST

- IT 업계에서의 A/B 테스트
  - 신규 기능 vs 기존 기능
  - '정말로 다르다'는 것을 데이터로 검증
  - 느낌이나 경험에 의존하지 않음



## 4. A/B TEST

- A/B 테스트 = 무작위 대조 실험 (RCT)
  - Randomized Controlled Trial
  - 실험군 vs 대조군
  - 인과 추론의 표준


## 4. A/B TEST

- 무작위 대조 실험이란?
  - 변경사항의 영향을 추정
  - 다른 변수들은 통제하거나 무작위화
  - 변경 효과만 남김

## 4. A/B TEST

- 예시: 스타벅스 사이렌 오더

- 가설: 홈 화면을 바꾸면 매출이 오른다
- 기존 화면 vs 새로운 화면
- 사용자 무작위 배정



## 4. A/B TEST

- 실험 설계

- 일부 사용자: 기존 홈 화면
- 일부 사용자: 새로운 홈 화면
- 무작위로 노출

## 4. A/B TEST

- A/B 테스트의 두 가지 핵심 조건
  - 변수 통제
  - 무작위 배정



## 4. A/B TEST

- 변수 통제

- 홈 화면 외 요소는 동일
- 결과에 영향을 줄 수 있는 요인 제거

## 4. A/B TEST

- 무작위 배정

- 사용자 성향 차이 제거
- 통제 불가능한 변수 완화

## 4. A/B TEST

- 왜 인과관계 추론에 강한가?

- 교란 변수 최소화
- 변경 효과만 남김



## 4. A/B TEST

- 산업 전반에서의 활용
  - IT 서비스
  - 마케팅
  - 정책·의료

## 4. A/B TEST

- FDA와 신약 실험
  - 신약 효능 검증
  - 유일하게 인정되는 방식

## 4. A/B TEST

- 핵심

- A/B 테스트는 가설을 검증하기 위한 무작위 대조 실험
- 현실 환경에서 인과관계를 추론할 수 있는 가장 강력한 방법임

STATISTICS

## 4. A/B TEST

왜 A/B 테스트를 해야 할까?

## 4. A/B TEST

- 왜 A/B 테스트를 해야 할까?
  - 가설은 틀릴 수 있음
  - 느낌과 직관은 자주 빗나감
  - 검증이 필요




## 4. A/B TEST

- **프로덕트 개발 = 가설의 연속**
  - 새로운 기능
  - UI/UX 변경
  - 정책 수정

## 4. A/B TEST

- 예시: Waze 음성 제보 기능

- 기존: 버튼을 눌러 제보
- 신규: 음성으로 제보
- 더 쉬워질 것 같음



## 4. A/B TEST

- 이 가설의 구조

- 변경사항: 음성 제보 도입
- 이유: 운전 중 제보가 쉬워짐
- 기대 결과: 제보율 증가



STATISTICS

## 4. A/B TEST



HYERI KANG

## 4. A/B TEST

- 하지만... 가설은 틀릴 수 있다
  - 전체 시장에서는 성공
  - 특정 국가에서는 실패 가능

## 4. A/B TEST

- 이 결과의 의미

- 실패 ≠ 나쁜 결과
- 새로운 가설의 출발점

## 4. A/B TEST

- 관찰 연구 사례: 야간등과 근시
  - 야간등을 켜고 잔 아이
  - 근시 확률 증가

STATISTICS

## 4. A/B TEST



HYERI KANG



## 4. A/B TEST

- 하지만 결론은 틀렸음
  - 원인은 부모의 시력
  - 교란 변수 존재

## 4. A/B TEST

- 왜 이런 오류가 생겼을까?

- 교란 변수 통제 실패
- 무작위 배정 없음

## 4. A/B TEST

- 전/후 비교의 함정

- 변화 전 vs 변화 후
- 다른 변수 개입 가능



## 4. A/B TEST

- **Waze 사례를 다시 생각해보자**
  - 출시 전후 비교
  - 다른 변수 개입 가능

## 4. A/B TEST

- 같은 상황에서 A/B 테스트를 했다면
  - 대조군 vs 실험군
  - 같은 시간, 같은 환경

## 4. A/B TEST

- 이때 얻을 수 있는 결론
  - 차이가 없다면?
    - 기능 효과 없음

## 4. A/B TEST

- A/B 테스트의 또 다른 역할
  - 예상치 못한 영향 감지
  - 부작용 발견

## 4. A/B TEST

- 예: 사용자 경험 악화
  - 음성 안내 불가
  - 오제보 증가 가능



## 4. A/B TEST

- 그래서 A/B 테스트가 필요
  - 가설 검증
  - 인과 추론
  - 부작용 감지

## 4. A/B TEST

- 핵심

- A/B 테스트는 맞았는지 틀렸는지를 가리는 실험이 아니라
- 왜 그런 결과가 나왔는지를 이해하게 해주는 실험

## 4. A/B TEST

- 좋은 A/B 테스트의 출발점
  - 실험은 가설에서 시작
  - 가설이 없으면 실험도 없음



STATISTICS

## 4. A/B TEST




HYERI KANG

## 4. A/B TEST

- 좋은 가설의 3요소
  - 변경사항
  - 이유
  - 기대 결과

## 4. A/B TEST

- 예시: Spotify Meet Your DJ
- 음악 추천 이유를 음성으로 설명
- 생성형 AI 활용



## 4. A/B TEST

- 이 가설을 분해해보면
  - 변경사항: 추천 이유를 음성으로 설명
  - 이유: 추천 맥락을 이해
  - 기대 결과: 만족도 증가

## 4. A/B TEST

- 이 가설의 부족한 점
  - '만족도'는 모호하다
  - 측정이 어렵다



## 4. A/B TEST

- 이 가설의 부족한 점
  - 모호한 개념 → 측정 가능한 지표
  - 지표 없이는 검증 불가

## 4. A/B TEST

- 지표의 세 가지 종류

- 목표 지표
- 요인 지표
- 방어 지표

## 4. A/B TEST

- 목표 지표

- 궁극적인 목표
- 중요하지만 측정이 어려움



## 4. A/B TEST

- 목표 지표의 한계

- 설문은 비용·시간 큼
- 후행 지표는 둔감

## 4. A/B TEST

- 요인 지표

- 목표 지표와 상관
- 더 민감하게 반응

## 4. A/B TEST

- Spotify DJ의 요인 지표 예시
  - 추천 곡 건너뛰기 비율
  - 반복 재생 비율
  - 저장 비율

## 4. A/B TEST

- 가설을 다시 쓰면
  - 기대 결과를 지표로 표현
  - 검증 가능해짐

## 4. A/B TEST

- 요인 지표의 주의점

- 항상 목표 지표와 직결되진 않음
- 검증 필요



## 4. A/B TEST

- 방어 지표

- 부정적 영향 감지
- 전체 UX 보호

## 4. A/B TEST

- 방어 지표의 예

- 음악 다양성 감소
- 시스템 성능 저하

## 4. A/B TEST

- 핵심

- 좋은 A/B 테스트는 좋은 가설과 좋은 지표 정의에서 시작함
- 목표 지표, 요인 지표, 방어 지표를 구분해야 함



STATISTICS

## 4. A/B TEST

실험 환경 구축 & 실험 단위

HYERI KANG

## 4. A/B TEST

- 실험 환경 구축 & 실험 단위
  - 좋은 가설 + 좋은 지표  $\neq$  좋은 실험
  - 환경이 없으면 검증 불가

## 4. A/B TEST

- 실험 환경이란?

- 기능을 노출할 수 있어야 함
- 지표를 수집할 수 있어야 함
- 결과를 비교할 수 있어야 함

## 4. A/B TEST

- 실험 단위란?
  - 실험에 참여하는 최소 단위
  - 결과를 비교하는 기준

## 4. A/B TEST

- 실험 단위의 예

- 사용자
- 웹페이지
- 앱 기능
- 도시 / 국가
- 회사 / 조직



## 4. A/B TEST

- 예: 웹페이지 vs 사용자
  - 페이지 단위: 새로고침마다 다른 안
  - 사용자 단위: 항상 같은 안

## 4. A/B TEST

- 좋은 실험 단위의 조건 (1)
  - 가설에 포함된 지표 측정 가능

## 4. A/B TEST

- 좋은 실험 단위의 조건 (2)
  - 실험 단위 간 간섭이 없어야 함



## 4. A/B TEST

- 간섭의 예: 아마존 프라임 요금
  - 사용자 단위 실험
  - 정보 공유로 간섭 발생

## 4. A/B TEST

- 간섭을 피하려면?
  - 더 큰 단위 선택
  - 지역 / 국가 단위

## 4. A/B TEST

- 좋은 실험 단위의 조건 (3)
  - 실험의 검정력을 극대화해야 함
    - 표본 수 충분
    - 간섭 최소
    - 지표 측정 가능

## 4. A/B TEST

- 좋은 실험 단위의 조건 (4)
  - 실험 단위가 정해진 뒤
  - 무작위 할당

## 4. A/B TEST

- 왜 무작위여야 하는가
  - 교란 변수 제거
  - 집단 간 평균적 동질성



## 4. A/B TEST

- 무작위 배정의 효과
  - 사용자 특성 평균화
  - 인과 추론 가능

## 4. A/B TEST

- 핵심

- 좋은 A/B테스트는 가설과 지표뿐만이 아니라 실험 단위와 환경설계도 중요

STATISTICS

## 4. A/B TEST

### A/B 테스트를 하는 방법

HYERI KANG



## 4. A/B TEST

- A/B 테스트를 하는 방법
  - 설계 → 실행 → 판단
  - 통계 이전에 구조의 문제

## 4. A/B TEST

- 실험 설계에서 시작
  - 가설을 실험으로 번역
  - 설계가 비용과 정확도를 결정

## 4. A/B TEST

- 실험안 구성

- 대조군
- 하나 이상의 실험군

## 4. A/B TEST

- 기능 최적화를 위한 실험

- 하나의 가설
- 여러 구현안 비교

## 4. A/B TEST

- 예: 아마존 체크아웃 실험

- 가설: 절차를 줄이면 전환율 ↑
- 대조군: 3단계 체크아웃 (배송지 입력 -> 결제정보 입력 -> 입력정보 검토)
- 여러 안을 동시에 비교
  - 실험군 1: 2단계 체크아웃 (배송비 및 결제정보 동시 입력 -> 입력정보 검토)
  - 실험군 2: 1단계 체크아웃 (배송비 및 결제정보 동시 입력, 검토단계 없음)
  - 실험군 3: 즉시 체크아웃 (사용자 입력정보 없이 바로 결제)



## 4. A/B TEST

- 왜 여러 안을 동시에 비교할까?
  - 한 번의 실험
  - 실험 비용 증가하지만 더 많은 실험을 통해 어느 안이 좋을지 빠르게 알수 있음

## 4. A/B TEST

- 측정 지표 선택의 원칙
  - 지표는 여러 개일 수 있음
  - 표준편차가 낮은 지표가 유리

## 4. A/B TEST

- 표준편차가 낮으면 생기는 일
  - 필요 표본 수 감소
  - 실험 기간 단축
  - 검정력 증가
  - MDE 감소



## 4. A/B TEST

- 정리 - 실험 단위는 지표와 함께 정함
  - 지표 측정 가능해야 함
  - 표준편차 최소화

## 4. A/B TEST

- 실험 대상이란?

- 실험에 포함할 범위
- 조건을 만족하는 단위의 집합
- 표준 편차를 최소화하는 방향으로 정해져야 함

## 4. A/B TEST

- 유의수준 ( $\alpha$ )
  - 1종 오류를 허용하는 기준
  - 유의수준 시나리오 표

| 유의수준 | 시나리오                                   |
|------|----------------------------------------|
| 1%   | 1종 오류 비용이 큰 경우                         |
| 5%   | 1종 오류를 범할 확률을 감수하더라도 빠른 의사결정을 해야 하는 경우 |

## 4. A/B TEST

- 검정력 (Power)

- 효과를 놓치지 않을 확률
- 검정력 시나리오 표

| 검정력    | 시나리오                                  |
|--------|---------------------------------------|
| 90~95% | 2종 오류 비용이 큰 경우                        |
| 80%    | 2종 오류를 범할 확률을 감수하더라도 빠른 의사결정을 해야하는 경우 |

## 4. A/B TEST

- 최소 검출 가능 효과 (MDE)

- 실험이 볼 수 있는 최소 변화
- MDE 시나리오 표

| 효과     | 검정력     |
|--------|---------|
| < 1%   | < 80%   |
| 1%     | 80%     |
| ◦ > 1% | ◦ > 80% |



## 4. A/B TEST

- **검정력과 MDE의 관계**
  - MDE 수준 효과를 잡을 확률 = 검정력

## 4. A/B TEST

- 표본 수는 결과물
  - 기준의 결과
  - 직접 정하지 않음

## 4. A/B TEST

- 여러 지표가 있을 때의 원칙
  - 가장 큰 표본 수 기준



## 4. A/B TEST

- A/B 테스트 실행 절차 요약

- 가설 수립
- 실험안 구성
- 지표 선택
- 실험 단위·대상 설정
- 판단 기준 설정
- 실험 실행

## 4. A/B TEST

- 이 순서가 깨지면 생기는 일
  - 해석 불가
  - 결론 흔들림
  - 조직 신뢰 하락


## 4. A/B TEST

- 정리

- A/B 테스트는 통계 이전에 설계의 영역

STATISTICS

## 4. A/B TEST



HYERI KANG

STATISTICS

**THANK YOU**

HYERI KANG